



UNIVERSIDAD DE CÓRDOBA



Universidad Internacional
de Andalucía

TRABAJO FIN DE MÁSTER

MÁSTER UNIVERSITARIO EN INTELIGENCIA ARTIFICIAL APLICADA A ENTORNOS EMPRESARIALES Y FINANCIEROS

Desarrollo de un simulador interactivo de decisiones de
inversión en viviendas de uso turístico

Realizado por:

Iván Navarro Suero

Dirigido por:

José Antonio Fernández Gallardo

Curso 2025-2026

TÍTULO: Desarrollo de un simulador interactivo de decisiones de inversión en viviendas de uso turístico.

RESUMEN: El presente Trabajo Fin de Máster aborda el diseño y desarrollo de un simulador interactivo de soporte a la decisión de inversión en viviendas de uso turístico (VUT), que integra modelos predictivos de inteligencia artificial con un motor de análisis económico-financiero. El trabajo se enmarca en un contexto de creciente interés inversor por el alquiler turístico en España y de elevada complejidad decisional, derivada de la variabilidad de la demanda, la estructura de costes específica de esta modalidad y un riesgo regulatorio en aumento.

El simulador se ha construido íntegramente con herramientas de código abierto y datos públicos de Inside Airbnb para Madrid y Barcelona, sobre un conjunto depurado de 69 142 anuncios. Integra tres modelos predictivos: XGBoost para la estimación de la tasa de ocupación ($R^2 = 0,597$), Random Forest para el precio óptimo por noche ($R^2 = 0,696$) y Prophet para la proyección de la estacionalidad de la demanda. Las predicciones alimentan un motor financiero que calcula VAN, TIR, payback, rentabilidades y punto muerto de ocupación bajo tres escenarios —optimista, neutro y pesimista—, complementado con análisis de sensibilidad, interpretabilidad mediante valores SHAP y un módulo de informes en lenguaje natural de carácter determinista. La herramienta se ha desplegado públicamente mediante Streamlit.

Los resultados muestran que el sistema discrimina correctamente entre perfiles de inversión con distinta viabilidad y cuantifica la distancia de cada operación a su umbral de rentabilidad. Los casos de uso analizados evidencian que, a los precios actuales de adquisición en las zonas céntricas de Madrid y Barcelona, la viabilidad del alquiler turístico exige ocupaciones muy superiores a la mediana del mercado. Se concluye que es posible construir, con datos públicos, un sistema de soporte a la decisión riguroso, interpretable y accesible, de utilidad para inversores, gestores y analistas.

PALABRAS CLAVE: viviendas de uso turístico; inteligencia artificial; simulador de inversiones; aprendizaje automático; análisis de viabilidad; sistemas de soporte a la decisión.

TITLE: Development of an interactive simulator for investment decisions in short-term rental properties.

ABSTRACT: This Master's Thesis addresses the design and development of an interactive decision-support simulator for investment in short-term rental properties, integrating artificial intelligence predictive models with an economic-financial analysis engine. The work is framed within a context of growing investor interest in short-term rentals in Spain and high decision complexity, stemming from demand variability, the specific cost structure of this rental modality and increasing regulatory risk.

The simulator was built entirely with open-source tools and public data from Inside Airbnb for Madrid and Barcelona, based on a cleaned dataset of 69 142 active listings. It integrates three predictive models: XGBoost for occupancy rate estimation ($R^2 = 0.597$), Random Forest for optimal nightly price ($R^2 = 0.696$) and Prophet for demand seasonality forecasting. Predictions feed a financial engine that computes NPV, IRR, payback, profitability ratios and break-even occupancy under three scenarios —optimistic, neutral and pessimistic—, complemented by sensitivity analysis, model interpretability through SHAP values and a deterministic natural language reporting module. The tool has been publicly deployed using Streamlit.

Results show that the system correctly discriminates between investment profiles with different viability levels and quantifies the distance of each operation to its profitability threshold. The analysed use cases reveal that, at current acquisition prices in central areas of Madrid and Barcelona, short-term rental viability requires occupancy rates well above the market median. The thesis concludes that it is possible to build, using public data, a rigorous, interpretable and accessible decision-support system, useful for investors, property managers and financial analysts.

KEYWORDS: short-term rentals; artificial intelligence; investment simulator; machine learning; viability analysis; decision support systems.

DECLARACIÓN JURADA DE ORIGINALIDAD DEL TRABAJO FIN DE MÁSTER

D. Iván Navarro Suero con DNI 29626531R estudiante del Máster Universitario en Inteligencia Artificial Aplicada a Entornos Empresariales y Financieros.

DECLARO

Ser la persona autora del texto entregado y que no ha sido presentado con anterioridad, ni total ni parcialmente, para superar materias previamente cursadas en esta u otras titulaciones de cualquier otra institución de educación superior u otro tipo de fin.

Que, si he hecho uso de la inteligencia artificial (IA) para generación de alguno de los contenidos de este trabajo, este uso se ha indicado claramente. Se exceptúa de esta norma el uso de IA para la mejora y/o corrección gramatical de los textos (y no para su generación), en cuyo caso se recomienda indicar este uso, pero no es obligatorio.

Así mismo, declaro no haber trasgredido ninguna norma universitaria con respecto al plagio ni a las leyes establecidas que protegen la propiedad intelectual, así como que las fuentes utilizadas han sido citadas adecuadamente. La responsabilidad por un uso inadecuado de las referencias no puede trasladarse a las herramientas de IA.

Por último, declaro que conozco las sanciones penales en caso de infringir las leyes del plagio y de falsa declaración, y que firmo la presente con pleno uso de mis facultades y asumiendo todas las responsabilidades de ella derivada.

Firma
**NAVARRO
SUERO IVAN -
29626531R**
En Málaga, a 12 de junio de 2026

Firmado digitalmente
por NAVARRO SUERO
IVAN - 29626531R
Fecha: 2026.06.12
20:03:16 +02'00'

ÍNDICE DE CONTENIDO

1. INTRODUCCIÓN	1
1.1. Motivación y contexto	1
1.2. Justificación del trabajo	2
1.3. Objetivos del trabajo	4
1.3.1. Objetivo general	4
1.3.2. Objetivos específicos.....	4
1.4. Estructura del documento	5
2. MARCO TEÓRICO	7
2.1. El mercado de viviendas de uso turístico en España	7
2.2. Regulación de las VUT: marco normativo actual.....	9
2.3. Inteligencia artificial aplicada a la inversión inmobiliaria.....	12
2.4. Modelos de predicción de precios y ocupación	14
2.5. Rentabilidad y análisis de riesgo en alquiler turístico	16
2.6. Explicabilidad (XAI) y Regulación de la Inteligencia Artificial en Finanzas	18
2.6.1. El imperativo regulatorio: La AI Act y el derecho a la explicación.....	19
3. METODOLOGÍA.....	22
3.1. Fuentes de datos utilizadas y delimitación geográfica.....	22
3.2. Proceso de obtención y limpieza de datos	24
3.3. Definición de variables e indicadores económico-financieros	26
3.3.1. Inversión inicial y estructura de financiación.....	26
3.3.2. Ingresos, costes fijos y costes variables	27
3.3.3. Flujo de caja neto.....	28
3.3.4. VAN, TIR y Payback	29
3.4. Selección y justificación de los modelos de IA	30
3.5. Arquitectura del sistema	31

4. DESARROLLO DEL SIMULADOR	34
4.1. Modelos predictivos.....	34
4.1.1. Predicción de ocupación (XGBoost)	35
4.1.2. Predicción de precio óptimo por noche (Random Forest).....	36
4.1.3. Proyección de estacionalidad (Prophet)	37
4.2. Motor de escenarios financieros	38
4.3. Interfaz web interactiva con Streamlit	39
4.4. Interpretabilidad de los modelos (SHAP)	43
4.5. Módulo de reportes mediante IA Generativa.....	44
5. RESULTADOS Y DISCUSIÓN	46
5.1. Evaluación de los modelos de Machine Learning	46
5.1.1. Modelo XGBoost de predicción de ocupación.....	46
5.1.2. Modelo Random Forest de predicción de precio.....	47
5.1.3. Modelo Prophet de proyección estacional.....	48
5.2. Casos de uso del simulador interactivo.....	49
5.2.1. Caso de uso A: inversión en Madrid, barrio de Universidad	49
5.2.2. Caso de uso B: inversión en Barcelona, barrio de la Dreta de l'Eixample	52
5.3. Análisis de sensibilidad de indicadores financieros	54
6. CONCLUSIONES.....	56
6.1. Conclusiones principales	56
6.2. Limitaciones del trabajo.....	58
6.3. Líneas de trabajo futuras.....	60
7. REFERENCIAS	62
8. ANEXOS	65
Anexo A. Código fuente del simulador	65
Anexo B. Datos y licencias.....	70
Anexo C. Declaración de uso de inteligencia artificial generativa.....	71

ÍNDICE DE FIGURAS

Figura 1. Interfaz principal del simulador y panel lateral de parametrización del inmueble.	40
Figura 2. Módulo de estimaciones de los modelos XGBoost y Random Forest.	41
Figura 3. Gráfico de proyección de estacionalidad anual generado mediante Prophet. .	41
Figura 4. Módulo financiero interactivo y parametrización de la inversión.	41
Figura 5. Gráfico de flujos de caja netos proyectados.....	42
Figura 6. Explicabilidad del modelo de ocupación mediante valores SHAP locales.....	44
Figura 7. Informe ejecutivo y resultados financieros del Caso A (Madrid, Universidad).	51
Figura 8. Informe ejecutivo y resultados financieros del Caso B (Barcelona, la Dreta de l'Eixample).....	53
Figura 9. Curva de sensibilidad del VAN para el Caso A.	54
Figura 10. Curva de sensibilidad del VAN para el Caso B.	55

ÍNDICE DE TABLAS

Tabla 1. Métricas de evaluación del modelo XGBoost de predicción de ocupación.	36
Tabla 2. Métricas de evaluación del modelo Random Forest de predicción de precio por noche.....	37
Tabla 3. Factores de ajuste por escenario financiero.	38
Tabla 4. Anexo B. Diccionario de variables empleadas en los modelos predictivos.	71

1. INTRODUCCIÓN

El presente Trabajo Fin de Máster tiene por objeto el diseño y desarrollo de un simulador interactivo de decisiones de inversión en viviendas de uso turístico (VUT). Este simulador integra técnicas de inteligencia artificial, modelos de predicción y análisis económico-financiero con el fin de ofrecer una herramienta de soporte a la decisión aplicable en contextos empresariales e inversores reales.

El alquiler turístico de corta duración ha experimentado en España una expansión sin precedentes durante la última década, impulsado principalmente por plataformas digitales como Airbnb, Booking.com o Vrbo. Este fenómeno ha generado oportunidades de inversión significativas, pero también ha incrementado la complejidad del análisis de viabilidad de estos activos, dada la elevada variabilidad de los ingresos, la evolución de la regulación municipal y la heterogeneidad del mercado en función de la localización geográfica.

En este contexto, la toma de decisiones de inversión en viviendas de uso turístico requiere la integración de múltiples variables: precio de adquisición del inmueble, tasa de ocupación esperada, precio óptimo por noche, costes operativos, estructura de financiación, marco fiscal aplicable y riesgo regulatorio, entre otras. La dificultad de gestionar simultáneamente todas estas dimensiones justifica el desarrollo de una herramienta sistemática, rigurosa y accesible que permita evaluar la rentabilidad potencial de una inversión bajo diferentes escenarios.

1.1. Motivación y contexto

La motivación principal de este trabajo surge de la confluencia de dos realidades que definen el panorama económico actual en España. Por un lado, el mercado inmobiliario atraviesa una fase de alta demanda de activos destinados al alquiler de corta duración, especialmente en ciudades turísticas como Madrid y Barcelona. Por otro, la inteligencia artificial y el aprendizaje automático han alcanzado un nivel de madurez

tecnológica que permite su aplicación práctica en la predicción de variables de mercado, la simulación de escenarios y la generación automatizada de informes financieros.

Según datos del Instituto Nacional de Estadística, el número de viviendas turísticas en España ha experimentado un crecimiento sostenido durante la última década, concentrándose especialmente en grandes núcleos urbanos y destinos costeros. Madrid y Barcelona, en particular, presentan mercados de alquiler turístico con alta densidad, intensa presión regulatoria y una variabilidad de precios y ocupación que hace imprescindible disponer de herramientas analíticas avanzadas para evaluar correctamente la rentabilidad de una inversión.

Desde una perspectiva académica y profesional, la literatura sobre inversión inmobiliaria ha avanzado notablemente en la incorporación de modelos predictivos basados en machine learning (Choy & Ho, 2023; Wang et al., 2019). Sin embargo, persiste una brecha significativa entre los desarrollos teóricos y la disponibilidad de herramientas prácticas, interactivas y accesibles para inversores, gestores y analistas financieros. Este trabajo pretende contribuir a reducir dicha brecha mediante el desarrollo de un simulador funcional, metodológicamente riguroso y técnicamente documentado.

La elección de Madrid y Barcelona como ámbito geográfico de estudio responde a su posición de liderazgo en el mercado de viviendas de uso turístico a nivel nacional, a la disponibilidad de datos públicos y a la existencia de marcos regulatorios diferenciados que enriquecen el análisis comparativo. Ambas ciudades presentan características de mercado suficientemente distintas como para permitir una evaluación de la robustez del simulador ante entornos con diferentes niveles de competencia, ocupación media y regulación local.

1.2. Justificación del trabajo

La justificación de este trabajo se articula en tres planos complementarios: el plano económico y sectorial, el plano metodológico y el plano tecnológico.

Desde el plano económico y sectorial, el alquiler turístico de corta duración se ha consolidado como una modalidad de inversión inmobiliaria con rentabilidades potencialmente superiores al alquiler residencial tradicional (Segú, 2020). No obstante, esta mayor rentabilidad va acompañada de una mayor complejidad en la estimación de los ingresos y en la gestión del riesgo, derivada de la estacionalidad de la demanda, la dinámica competitiva de las plataformas digitales y la creciente intervención regulatoria de las administraciones locales (Yrigoy, 2019). Esta complejidad hace necesario disponer de un instrumento de análisis que vaya más allá de las hojas de cálculo convencionales y que incorpore capacidades predictivas y de simulación avanzadas.

Desde el plano metodológico, los modelos de valoración de activos inmobiliarios han evolucionado significativamente gracias a la incorporación de técnicas de machine learning, que han demostrado una capacidad predictiva superior a los modelos econométricos tradicionales en contextos de elevada complejidad y no linealidad (Choy & Ho, 2023). La aplicación de algoritmos como Random Forest, XGBoost o Prophet al análisis de viviendas de uso turístico permite modelar con mayor precisión variables clave como la ocupación esperada, el precio óptimo por noche o la estacionalidad de la demanda (Gibbs et al., 2018; Pérez-Sánchez et al., 2018).

Desde el plano tecnológico, el estado actual del desarrollo de herramientas de inteligencia artificial —incluyendo la IA generativa— abre la posibilidad de crear simuladores interactivos que no solo calculen indicadores financieros, sino que también interpreten los resultados en lenguaje natural, generen informes automáticos y asistan al usuario en la comprensión de los factores de riesgo. La integración de estas capacidades en una interfaz web accesible, desarrollada con frameworks como Streamlit, constituye una aportación relevante tanto desde el punto de vista académico como profesional.

En consecuencia, este trabajo se justifica por la existencia de una necesidad real no cubierta suficientemente por las herramientas existentes: la de disponer de un simulador de decisiones de inversión en VUT que combine rigor financiero, capacidades predictivas basadas en inteligencia artificial e interpretabilidad de resultados, en un entorno interactivo y accesible para usuarios con diferentes perfiles de conocimiento técnico.

1.3. Objetivos del trabajo

1.3.1. Objetivo general

El objetivo general del presente trabajo es diseñar y desarrollar un simulador interactivo de decisiones de inversión en viviendas de uso turístico que integre modelos predictivos basados en inteligencia artificial, indicadores económico-financieros y análisis de escenarios, con el fin de facilitar la evaluación de la viabilidad y rentabilidad de este tipo de inversiones en el mercado español, con especial referencia a los mercados de Madrid y Barcelona.

1.3.2. Objetivos específicos

Para la consecución del objetivo general, se plantean los siguientes objetivos específicos:

Revisar el estado del arte en materia de viviendas de uso turístico, regulación aplicable, modelos de predicción de precios y ocupación, e inteligencia artificial aplicada a la inversión inmobiliaria.

Identificar y definir las variables económico-financieras, operativas y de riesgo que determinan la rentabilidad de una vivienda de uso turístico, estableciendo un modelo de cálculo coherente y replicable.

Seleccionar, entrenar y evaluar modelos de inteligencia artificial para la predicción de la tasa de ocupación, el precio óptimo por noche y la estacionalidad de la demanda en las ciudades de Madrid y Barcelona.

Diseñar e implementar un motor de escenarios financieros —optimista, neutro y pesimista— que permita evaluar la sensibilidad de los indicadores de rentabilidad ante variaciones en las principales variables del modelo.

Desarrollar una interfaz web interactiva que integre los modelos predictivos, el motor financiero y un módulo de generación de informes automatizados mediante inteligencia artificial generativa, facilitando su uso por parte de inversores, gestores y analistas.

Validar el funcionamiento del simulador mediante casos de uso representativos de los mercados de Madrid y Barcelona, analizando la comparativa de viabilidad entre ambas ciudades y contrastando los resultados con referencias del mercado.

1.4. Estructura del documento

Con el fin de facilitar la lectura y comprensión del presente trabajo, a continuación, se describe brevemente el contenido de cada uno de los capítulos que lo integran.

El Capítulo 2 recoge el Marco Teórico. En él se analiza el mercado de viviendas de uso turístico en España, con especial atención a la regulación normativa vigente y su evolución reciente. Asimismo, se revisa la literatura académica sobre la aplicación de la inteligencia artificial a la inversión inmobiliaria, los modelos de predicción de precios y ocupación, y los fundamentos del análisis de rentabilidad y riesgo en el alquiler turístico.

El Capítulo 3 describe la Metodología del trabajo. Se detallan las fuentes de datos utilizadas, el proceso de obtención y limpieza de la información, la definición de las variables e indicadores económico-financieros del modelo —incluyendo los indicadores VAN, TIR y payback—, la selección y justificación de los modelos de inteligencia artificial empleados y la arquitectura general del sistema.

El Capítulo 4 aborda el Desarrollo del Simulador. Se describen los modelos predictivos implementados —predicción de ocupación mediante XGBoost, estimación de precio óptimo por noche mediante Random Forest y proyección de estacionalidad mediante Prophet—, el motor de escenarios financieros, la interfaz web interactiva

desarrollada con Streamlit, el análisis de interpretabilidad mediante SHAP y el módulo de generación de informes automatizados mediante IA generativa.

El Capítulo 5 presenta los Resultados y la Discusión. Se evalúa el rendimiento de los modelos de machine learning, se analizan casos de uso representativos del simulador, se realiza un análisis de sensibilidad de los indicadores financieros y se lleva a cabo una comparativa de viabilidad entre los mercados de Madrid y Barcelona.

El Capítulo 6 recoge las Conclusiones del trabajo, incluyendo las principales aportaciones, las limitaciones identificadas y las líneas de investigación futura que se desprenden de los resultados obtenidos.

El documento concluye con las Referencias bibliográficas y los Anexos, que incluyen el código fuente del simulador, las fuentes de datos y licencias utilizadas, y el detalle del uso de inteligencia artificial generativa en la elaboración del trabajo.

2. MARCO TEÓRICO

El presente capítulo establece el marco conceptual y teórico sobre el que se sustenta el desarrollo del simulador. En primer lugar, se caracteriza el mercado de viviendas de uso turístico en España, su dimensión económica y su dinámica reciente. En segundo lugar, se analiza el marco normativo aplicable en sus tres niveles —estatal, autonómico y municipal—, con especial atención a las regulaciones de Madrid y Barcelona. A continuación, se revisa la literatura sobre la aplicación de la inteligencia artificial a la inversión inmobiliaria y los modelos de predicción de precios y ocupación en plataformas de alquiler turístico. El capítulo se cierra con los fundamentos del análisis de rentabilidad y riesgo aplicados al alquiler turístico, que constituyen la base conceptual del motor financiero del simulador.

2.1. El mercado de viviendas de uso turístico en España

La vivienda de uso turístico (VUT) se define como aquel inmueble residencial que se cede temporalmente a terceros, de forma reiterada y a cambio de contraprestación económica, para estancias de corta duración, habitualmente comercializado a través de plataformas digitales de intermediación. Este fenómeno, también denominado alquiler de corta duración (ACD) en la literatura sectorial, ha experimentado un crecimiento extraordinario en España durante la última década, impulsado por la expansión de plataformas como Airbnb, Booking.com o Vrbo, que han reducido drásticamente los costes de transacción entre propietarios y huéspedes (Yrigoy, 2019).

España constituye uno de los principales mercados mundiales de alquiler turístico, en coherencia con su posición como segunda potencia turística global por número de visitantes internacionales. El parque de viviendas turísticas se concentra de forma muy desigual en el territorio: los grandes núcleos urbanos —Madrid y Barcelona— y los destinos costeros e insulares acumulan la mayor parte de la oferta, mientras que en el interior peninsular su presencia es marginal. Esta concentración espacial tiene

implicaciones directas tanto para la rentabilidad esperada de la inversión como para la intensidad de la respuesta regulatoria local.

El informe de PwC-Strategy& (2024) sobre el impacto del alquiler de corta duración en España aporta una caracterización empírica relevante de la oferta. Según la encuesta realizada a propietarios, el 63 % de las propiedades de alquiler de corta duración no se dedican principalmente al alquiler turístico, sino que son residencias —principales o secundarias— que se alquilan de forma ocasional, durante menos de un tercio del año. Únicamente el 37 % de los ACD se explota de manera intensiva como alojamiento turístico. Esta distinción resulta esencial para el presente trabajo, pues el perfil de inversor al que se dirige el simulador corresponde precisamente al segmento de explotación intensiva, donde la decisión de inversión se evalúa con criterios estrictamente económico-financieros.

En términos de dimensión relativa, el fenómeno presenta magnitudes inferiores a las que el debate público sugiere. En Madrid, las 14 133 viviendas de uso turístico identificadas representan el 0,92 % del parque total de viviendas de la ciudad, si bien su concentración es muy elevada en el distrito Centro, donde el 44 % de los ACD de la ciudad alcanza el 7,6 % del parque residencial del distrito (PwC-Strategy&, 2024). Esta concentración espacial en zonas de alta demanda turística es precisamente la que genera tanto las oportunidades de rentabilidad para el inversor como las externalidades que motivan la respuesta regulatoria municipal.

Desde la perspectiva de la inversión, el atractivo de las VUT frente al alquiler residencial tradicional radica en el diferencial de ingresos potenciales. El alquiler turístico permite obtener un ingreso por noche significativamente superior al equivalente diario del alquiler de larga duración, a cambio de asumir mayor variabilidad de la demanda, mayores costes operativos —limpieza, gestión de reservas, suministros, comisiones de plataforma— y un riesgo regulatorio creciente. La literatura económica ha documentado además los efectos de la expansión del alquiler turístico sobre el mercado residencial: García-López et al. (2020) estiman, para el caso de Barcelona, que la presencia de Airbnb explica un incremento apreciable de los alquileres residenciales en los barrios con mayor

penetración de la plataforma, lo que ha alimentado el debate sobre la regulación del sector.

Los informes sectoriales más recientes confirman el interés inversor sostenido en el segmento. El Real Estate Market Outlook Spain 2025 de CBRE señala el segmento living y el alojamiento turístico entre los destinos preferentes del capital inversor en España, en un contexto de recuperación de los volúmenes de inversión inmobiliaria. Por su parte, el informe de Colliers (2025) sobre los mercados de Madrid y Barcelona destaca la divergencia regulatoria entre ambas ciudades como un factor determinante de las estrategias de inversión: mientras Madrid mantiene un marco restrictivo pero con expectativas de ordenación, Barcelona ha anunciado la eliminación completa de las licencias de VUT en el horizonte de 2028, lo que introduce un riesgo regulatorio extremo para las inversiones en esa ciudad.

Esta combinación de rentabilidades potencialmente elevadas, costes operativos significativos, alta variabilidad de la demanda y riesgo regulatorio creciente configura un problema de decisión de inversión de notable complejidad, que justifica el desarrollo de herramientas cuantitativas de soporte a la decisión como la que se propone en este trabajo.

2.2. Regulación de las VUT: marco normativo actual

El marco normativo aplicable a las viviendas de uso turístico en España se caracteriza por su fragmentación en tres niveles administrativos —estatal, autonómico y municipal— con competencias diferenciadas, lo que genera un mosaico regulatorio de elevada complejidad y en constante evolución (PwC-Strategy&, 2024).

En el nivel estatal, el Estado carece de competencias directas en materia de ordenación turística, transferidas a las comunidades autónomas, pero dispone de instrumentos normativos transversales que afectan a la actividad. Destacan tres hitos recientes. En primer lugar, el Real Decreto 933/2021, de 26 de octubre, por el que se establecen las obligaciones de registro documental e información de las personas físicas o jurídicas que ejercen actividades de hospedaje y alquiler de vehículos a motor, extiende

a las viviendas turísticas comercializadas a través de plataformas digitales las obligaciones de registro de viajeros y comunicación de datos a las Fuerzas y Cuerpos de Seguridad que tradicionalmente correspondían a los establecimientos hoteleros. La norma reconoce expresamente que las "viviendas turísticas de corta duración explotadas por empresas o particulares mediante el registro en portales o centrales de reserva" habían quedado fuera del ámbito de aplicación de la normativa anterior, y les impone obligaciones de registro documental cuyo incumplimiento constituye infracción grave.

En segundo lugar, la Ley 12/2023, de 24 de mayo, por el derecho a la vivienda, introduce el concepto de zona de mercado residencial tensionado, que habilita a las administraciones competentes a aplicar medidas de contención de rentas en los contratos de arrendamiento residencial. Aunque la ley no regula directamente el alquiler turístico, su incidencia sobre el mercado de VUT es doble: por una parte, la limitación de rentas en el alquiler residencial puede incrementar el atractivo relativo del alquiler turístico para los propietarios, intensificando el trasvase de viviendas entre ambos mercados; por otra, la propia ley prevé el refuerzo de los sistemas de información sobre arrendamientos, antesala de una mayor capacidad de control administrativo sobre los usos del parque residencial.

En tercer lugar, la modificación de la Ley de Propiedad Horizontal, en vigor desde 2025, exige la aprobación expresa de la comunidad de propietarios para el inicio de la actividad de alquiler turístico en una vivienda, por mayoría de tres quintos, lo que añade una barrera de entrada adicional y un riesgo previo a la adquisición que el inversor debe verificar.

En el nivel autonómico, las comunidades autónomas ostentan la competencia en materia de ordenación del turismo y han desarrollado normativas específicas que definen la figura de la vivienda de uso turístico, establecen los requisitos de calidad y habitabilidad, y regulan los regímenes de declaración responsable o autorización previa. La Comunidad de Madrid regula las VUT mediante el Decreto 79/2014, modificado posteriormente, que exige el Certificado de Idoneidad para Vivienda de Uso Turístico y la inscripción en el registro autonómico. Cataluña, por su parte, dispone de una regulación pionera a través de la normativa turística catalana, que somete las viviendas de uso

turístico a un régimen de licencia municipal previa y habilita a los municipios a establecer limitaciones cuantitativas y zonales (PwC-Strategy&, 2024).

El nivel municipal concentra, en la práctica, los instrumentos más restrictivos, principalmente a través del planeamiento urbanístico. Barcelona constituye el caso paradigmático de regulación restrictiva: tras la suspensión de licencias de 2014, el Plan Especial Urbanístico de Alojamientos Turísticos (PEUAT) de 2017, modificado en 2022, estableció una zonificación de la ciudad con áreas de decrecimiento donde no se permite la creación de nuevas VUT, áreas de mantenimiento donde solo se permiten nuevas licencias si otras se extinguen, y áreas de crecimiento limitado. Adicionalmente, el consistorio ha anunciado la voluntad de eliminar completamente las viviendas de uso turístico de la ciudad en 2028, mediante la no renovación de las licencias existentes (PwC-Strategy&, 2024). Madrid, por su parte, aprobó en 2019 el Plan Especial de regulación del uso de servicios terciarios en la clase de hospedaje, que exige acceso independiente desde la vía pública para las VUT situadas en edificios residenciales —requisito que limita severamente la oferta legal viable—, y en 2024 activó un plan de acción que congela la concesión de nuevas licencias y endurece el régimen sancionador, con multas que pueden alcanzar los 190 000 EUR por operar sin licencia (PwC-Strategy&, 2024).

Para el presente trabajo, este marco regulatorio tiene una doble implicación. En primer lugar, constituye una variable de riesgo de primer orden que el inversor debe incorporar a su análisis: la posibilidad de cambios normativos que restrinjan o impidan la actividad afecta directamente a la generación de flujos de caja futuros y, por tanto, al valor actual neto de la inversión. En segundo lugar, justifica la inclusión en el simulador de escenarios pesimistas con caídas significativas de ingresos, que permiten aproximar el impacto de un endurecimiento regulatorio sobre la viabilidad de la operación. El simulador no modeliza explícitamente el riesgo regulatorio como variable probabilística, pero su arquitectura de escenarios permite al usuario evaluar la resistencia de la inversión ante contracciones severas de la actividad.

2.3. Inteligencia artificial aplicada a la inversión inmobiliaria

La aplicación de técnicas de inteligencia artificial al análisis inmobiliario ha experimentado un desarrollo notable durante la última década, en paralelo a la creciente disponibilidad de datos masivos sobre transacciones, anuncios y características de los inmuebles. La literatura distingue dos grandes líneas de aplicación: la valoración automatizada de activos (Automated Valuation Models, AVM) y la predicción de variables de mercado relevantes para la decisión de inversión, como rentas, ocupación o demanda.

El enfoque tradicional de valoración inmobiliaria se ha apoyado en los modelos de precios hedónicos, cuyo fundamento teórico se remonta a Lancaster (1966), según el cual el precio de un bien heterogéneo refleja la valoración implícita que el mercado asigna a cada uno de sus atributos. En su formulación econométrica clásica, los modelos hedónicos estiman mediante regresión lineal la contribución marginal de cada característica —superficie, localización, antigüedad, equipamiento— al precio del inmueble. Esta aproximación, aunque interpretable y teóricamente fundamentada, presenta limitaciones conocidas: asume formas funcionales lineales o log-lineales, captura con dificultad las interacciones entre variables y es sensible a la multicolinealidad entre atributos.

Los algoritmos de machine learning superan varias de estas limitaciones. Los métodos de ensamblado de árboles de decisión —Random Forest y Gradient Boosting, en sus distintas implementaciones— permiten modelar relaciones no lineales y de interacción compleja entre las características del inmueble y la variable objetivo, sin necesidad de especificar a priori la forma funcional, y presentan una robustez superior frente a valores atípicos y variables irrelevantes (Choy & Ho, 2023). La evidencia empírica comparada es consistente: en ejercicios de predicción de precios inmobiliarios, los modelos de ensamblado superan sistemáticamente a la regresión hedónica clásica en capacidad predictiva, a costa de una menor interpretabilidad directa de los coeficientes (Wang et al., 2019; Choy & Ho, 2023).

Esta pérdida de interpretabilidad —el denominado problema de la caja negra— ha sido abordada por una línea de investigación específica dentro del aprendizaje automático: la interpretabilidad de modelos o explainable AI (XAI). El método de referencia en la actualidad son los valores SHAP (SHapley Additive exPlanations), propuestos por Lundberg y Lee (2017), que adaptan el concepto de valor de Shapley de la teoría de juegos cooperativos para descomponer la predicción individual de un modelo en contribuciones aditivas de cada variable. Los valores SHAP poseen propiedades teóricas deseables —eficiencia, simetría, aditividad— y disponen de implementaciones computacionalmente eficientes para modelos basados en árboles, lo que los convierte en el estándar de facto para explicar predicciones de modelos de ensamblado en aplicaciones financieras, donde la justificación de las decisiones es un requisito tanto práctico como, crecientemente, normativo.

En el ámbito específico de la decisión de inversión, la inteligencia artificial se integra en los denominados sistemas de soporte a la decisión (Decision Support Systems, DSS), entendidos como sistemas de información interactivos que combinan datos, modelos analíticos e interfaces de usuario para asistir la toma de decisiones semiestructuradas. La arquitectura clásica de un DSS —subsistema de datos, subsistema de modelos y subsistema de diálogo— mantiene plena vigencia conceptual, si bien sus componentes se han transformado: los modelos estadísticos clásicos han dado paso a modelos de machine learning, y las interfaces tradicionales han evolucionado hacia aplicaciones web interactivas que permiten la exploración de escenarios en tiempo real. El simulador desarrollado en este trabajo responde exactamente a esta arquitectura: un subsistema de datos construido sobre Inside Airbnb, un subsistema de modelos que integra predictores de machine learning y un motor financiero determinista, y un subsistema de diálogo materializado en una interfaz web interactiva.

Finalmente, la irrupción de la inteligencia artificial generativa ha abierto una nueva dimensión en los DSS: la generación automática de explicaciones e informes en lenguaje natural. La traducción de resultados cuantitativos complejos a narrativas comprensibles reduce la carga cognitiva del decisor y amplía el espectro de usuarios capaces de aprovechar la herramienta. No obstante, como se justifica en el Capítulo 4, en contextos financieros el determinismo y la fidelidad numérica del informe son requisitos

prioritarios, lo que aconseja arquitecturas de generación de lenguaje natural basadas en reglas frente a modelos generativos probabilísticos cuando el contenido del informe debe ser matemáticamente exacto.

2.4. Modelos de predicción de precios y ocupación

La literatura específica sobre predicción de precios y demanda en plataformas de alquiler turístico se ha desarrollado de forma acelerada desde mediados de la década pasada, impulsada por la disponibilidad de datos masivos de anuncios a través de iniciativas como Inside Airbnb. Esta sección revisa los principales antecedentes que fundamentan las decisiones de modelización adoptadas en el presente trabajo.

En el ámbito de la predicción de precios, el trabajo de referencia es el de Gibbs et al. (2018), que aplica modelos de precios hedónicos a datos de Airbnb en cinco ciudades canadienses, identificando como determinantes principales del precio los atributos físicos del inmueble —capacidad, habitaciones, baños—, la localización y los atributos de reputación del anfitrión. Los autores documentan asimismo que una proporción muy significativa de anfitriones fija precios de forma subóptima, sin ajustarlos a la demanda, lo que sugiere la existencia de un margen de mejora mediante herramientas cuantitativas de pricing, conclusión directamente relevante para la funcionalidad de estimación de precio óptimo del simulador.

Para el caso español, Pérez-Sánchez et al. (2018) analizan los determinantes del precio de los anuncios de Airbnb en ciudades del litoral mediterráneo mediante modelos hedónicos, confirmando el papel dominante del tamaño del inmueble y la localización, junto a atributos específicos del alquiler turístico como la política de cancelación o la condición de superhost. Estos resultados constituyen la referencia empírica nacional más próxima al ámbito del presente trabajo y se utilizan en el Capítulo 5 para contrastar la validez de los resultados del modelo de precio.

En cuanto a los métodos, la evidencia comparada favorece sistemáticamente a los algoritmos de ensamblado de árboles. Choy y Ho (2023) comparan regresión lineal,

Random Forest y Gradient Boosting en la predicción de precios inmobiliarios, concluyendo que los métodos de ensamblado obtienen mejoras sustanciales de capacidad predictiva, con valores de R^2 que en aplicaciones a datos de alquiler turístico se sitúan típicamente en el rango de 0,50 a 0,70 en función de la riqueza de las variables disponibles. Wang et al. (2019) alcanzan conclusiones análogas en la predicción de rentas, destacando además la capacidad de los modelos de árboles para gestionar variables categóricas de alta cardinalidad, como el barrio, particularmente relevantes en datos inmobiliarios urbanos.

La predicción de la ocupación presenta dificultades metodológicas específicas que la literatura ha documentado con detalle. La principal es que las plataformas no publican datos directos de reservas, por lo que la ocupación debe estimarse a partir de variables observables. Inside Airbnb aplica el denominado Modelo de San Francisco, que estima la ocupación a partir del número de reseñas recibidas multiplicado por un factor corrector de la tasa de reseña. Esta construcción tiene una consecuencia metodológica crítica para la modelización: las variables de reseñas no pueden utilizarse como predictores de la ocupación así estimada, pues constituyen la propia variable objetivo de forma encubierta, generando una fuga de información (data leakage) que invalida el modelo para su propósito real. Alsudais (2021) documenta adicionalmente las limitaciones de precisión de los datos de Inside Airbnb, recomendando su uso con las debidas cautelas metodológicas. En el presente trabajo, la detección y corrección de este problema —descrita en el Capítulo 4— constituye una de las decisiones metodológicas centrales del proceso de modelización.

Respecto a los determinantes de la demanda, Magno et al. (2018) analizan el efecto de la condición de superhost sobre el rendimiento de los anuncios, documentando que los anfitriones con esta distinción obtienen mayores tasas de ocupación y pueden sostener precios superiores, efecto atribuible a la reducción de la asimetría informativa entre anfitrión y huésped en mercados con elevada incertidumbre sobre la calidad. Jiao y Bai (2020) estudian la distribución espacial de la actividad de Airbnb en ciudades estadounidenses mediante técnicas de análisis geoespacial, confirmando la fuerte concentración de la demanda en zonas centrales y turísticas, patrón plenamente coherente con la concentración observada en Madrid y Barcelona.

La dimensión temporal de la demanda turística —su estacionalidad— ha sido tradicionalmente abordada mediante modelos de series temporales de la familia ARIMA. No obstante, en series con estacionalidad múltiple y efectos de calendario, como las de ocupación turística, los modelos aditivos estructurales presentan ventajas operativas. Prophet, desarrollado por Taylor y Letham (2018), descompone la serie en tendencia, estacionalidades y efectos de festivos mediante un modelo aditivo generalizado, ofreciendo robustez ante datos ausentes y valores atípicos, e interpretabilidad directa de los componentes. Estas propiedades justifican su adopción en el presente trabajo para la proyección de la estacionalidad de la ocupación, como se desarrolla en el Capítulo 4.

2.5. Rentabilidad y análisis de riesgo en alquiler turístico

La evaluación económico-financiera de una inversión en vivienda de uso turístico se fundamenta en los principios clásicos del análisis de inversiones, articulados en torno al descuento de flujos de caja. Esta sección presenta los fundamentos conceptuales de los indicadores implementados en el motor financiero del simulador.

El criterio central de decisión es el Valor Actual Neto (VAN), definido como la suma de los flujos de caja netos esperados de la inversión, descontados a una tasa que refleja el coste de oportunidad del capital, menos el desembolso inicial. Un VAN positivo indica que la inversión genera valor por encima de la rentabilidad exigida; un VAN negativo, que la destruye. La tasa de descuento incorpora el coste de oportunidad de inversiones alternativas de riesgo comparable y una prima por el riesgo específico del activo. En el contexto del alquiler turístico, esta prima debe reflejar la elevada variabilidad de los ingresos y el riesgo regulatorio descrito en el apartado 2.2.

La Tasa Interna de Retorno (TIR) es la tasa de descuento que anula el VAN, e indica la rentabilidad anual compuesta implícita en los flujos de la inversión. Su interpretación conjunta con el VAN permite al inversor comparar la rentabilidad de la operación con su coste de capital y con inversiones alternativas. El payback o plazo de recuperación —en sus variantes simple y descontada— mide el número de años necesario

para recuperar el capital invertido, y constituye un indicador complementario de liquidez y exposición temporal al riesgo, especialmente relevante en activos sujetos a riesgo regulatorio con horizonte incierto: cuanto menor es el payback, menor es la exposición de la inversión a un eventual endurecimiento normativo futuro.

Junto a estos indicadores de rentabilidad absoluta, el análisis inmobiliario emplea ratios de rentabilidad relativa. La rentabilidad bruta relaciona los ingresos anuales con el precio de adquisición; la rentabilidad neta deduce de los ingresos la totalidad de los costes operativos y los relaciona con la inversión total; y la rentabilidad sobre el capital propio (ROE) mide el rendimiento obtenido sobre los fondos efectivamente aportados por el inversor, capturando el efecto del apalancamiento financiero. El apalancamiento mediante deuda hipotecaria amplifica la rentabilidad del capital propio cuando la rentabilidad económica del activo supera el coste de la deuda, pero amplifica igualmente las pérdidas en el escenario contrario, incrementando el riesgo financiero de la operación. Este efecto amplificador, documentado en la literatura sobre inversión inmobiliaria apalancada, justifica que el simulador calcule explícitamente el ROE y diferencie entre la rentabilidad del activo y la rentabilidad del inversor.

Una particularidad del alquiler turístico frente al residencial es la estructura de costes, con un peso muy superior de los costes variables ligados a la rotación de huéspedes —limpieza, comisiones de plataforma, gestión de entradas y salidas— y de los costes de comercialización. Esta estructura determina la relevancia del punto muerto de ocupación, definido como la tasa de ocupación mínima que iguala los ingresos a la totalidad de los costes operativos y financieros del ejercicio. El punto muerto constituye el principal indicador de riesgo operativo de la inversión: la diferencia entre la ocupación esperada y el punto muerto —el margen de seguridad— cuantifica la capacidad de la operación para absorber caídas de demanda sin entrar en pérdidas de caja.

La incertidumbre inherente a las variables del modelo —ocupación, precio por noche, costes, tipos de interés— exige completar el análisis determinista con técnicas de análisis de riesgo. Las dos aproximaciones canónicas son el análisis de escenarios y el análisis de sensibilidad. El análisis de escenarios evalúa la inversión bajo conjuntos coherentes de hipótesis —típicamente optimista, base y pesimista—, proporcionando una

visión del rango de resultados posibles. El análisis de sensibilidad, por su parte, cuantifica la variación del indicador de decisión —habitualmente el VAN— ante variaciones unitarias de una variable crítica, manteniendo constantes las demás, lo que permite identificar las variables cuyo comportamiento condiciona en mayor medida la viabilidad de la inversión. Ambas técnicas, estándar en la práctica del análisis de inversiones y en la literatura de finanzas corporativas, constituyen el fundamento conceptual del motor de escenarios y del módulo de sensibilidad del simulador desarrollado en este trabajo.

En síntesis, el marco teórico expuesto fundamenta las tres decisiones de diseño centrales del simulador: la adopción de modelos de machine learning de ensamblado de árboles para la predicción de ocupación y precio, dada su superioridad empírica documentada en datos inmobiliarios; la incorporación de interpretabilidad mediante valores SHAP, como respuesta al requisito de explicabilidad en decisiones financieras; y la articulación del análisis de viabilidad en torno al descuento de flujos de caja con análisis de escenarios y sensibilidad, conforme a los principios establecidos del análisis de inversiones.

2.6. Explicabilidad (XAI) y Regulación de la Inteligencia Artificial en Finanzas

La adopción de modelos de aprendizaje automático (machine learning) en la toma de decisiones financieras ha planteado un desafío fundamental en la literatura reciente: el equilibrio entre la capacidad predictiva del modelo y su interpretabilidad. Los algoritmos que habitualmente ofrecen un mayor rendimiento predictivo, como los métodos de ensamblado de árboles (Random Forest, XGBoost) o las redes neuronales profundas, se caracterizan por una opacidad inherente. Operan como sistemas de "caja negra" (black-box), donde la relación no lineal entre las variables de entrada y la predicción final resulta indescifrable de forma directa para el analista humano.

En el contexto de la inversión inmobiliaria y el análisis de rentabilidad, operar con modelos opacos resulta inasumible por tres motivos estructurales: la gestión del riesgo, la confianza del inversor y, de forma creciente, el cumplimiento normativo. Un decisor no comprometerá un capital intensivo basándose exclusivamente en el resultado numérico de un algoritmo si no es capaz de auditar la lógica económica subyacente que justifica dicha predicción.

2.6.1. El imperativo regulatorio: La AI Act y el derecho a la explicación

Esta necesidad de transparencia ha cristalizado en un marco regulatorio europeo estricto. La entrada en vigor del Reglamento Europeo de Inteligencia Artificial (AI Act) ha establecido una categorización de los sistemas algorítmicos basada en el nivel de riesgo. Aquellos sistemas de inteligencia artificial empleados para evaluar la solvencia crediticia, fijar precios de activos o asistir en decisiones financieras de alto impacto están sometidos a requisitos rigurosos de transparencia, trazabilidad y supervisión humana (human-in-the-loop).

Adicionalmente, el Reglamento General de Protección de Datos (RGPD), en sus artículos 13 a 15 y 22, ya sentó las bases normativas del denominado "derecho a la explicación", exigiendo que los sujetos afectados por decisiones algorítmicas reciban información significativa sobre la lógica aplicada. En este paradigma, la Explicabilidad de la Inteligencia Artificial (Explainable AI o XAI) ha dejado de ser una característica analítica deseable para convertirse en un requisito legal y metodológico ineludible en el ecosistema de las finanzas cuantitativas. El simulador desarrollado en el presente trabajo se alinea proactivamente con estas exigencias normativas al rechazar el enfoque de caja negra e integrar mecanismos avanzados de interpretabilidad local y global.

2.6.2. Fundamentación matemática: Valores SHAP como solución de confianza

Para resolver la disyuntiva entre precisión predictiva y opacidad en los modelos XGBoost y Random Forest implementados en el simulador, se ha adoptado el marco metodológico de los valores SHAP (SHapley Additive exPlanations), propuesto por Lundberg y Lee (2017).

El rigor matemático de la metodología SHAP radica en la aplicación de la teoría de juegos cooperativos, formulada originariamente por Lloyd Shapley (1953). En este marco conceptual, la predicción del modelo se define como un "juego", las variables predictoras (características del inmueble, parámetros de mercado) actúan como los "jugadores" que cooperan, y el resultado de la predicción (por ejemplo, la tasa de ocupación estimada) es el "pago" a repartir.

El objetivo analítico es calcular la contribución marginal exacta de cada variable a la predicción final de una forma matemáticamente justa y aditiva. El valor de Shapley para una variable i se define mediante la siguiente ecuación:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|! (|F| - |S| - 1)!}{|F|!} [f(S \cup \{i\}) - f(S)]$$

Donde F es el conjunto total de todas las variables que conforman el modelo; S es un subconjunto de variables que no contiene a la variable i ; $f(S)$ representa la predicción del modelo condicionada exclusivamente a los valores del subconjunto de variables S ; y el factor multiplicativo combinatorio representa la probabilidad o ponderación de que el subconjunto S ocurra, calculada a partir de las permutaciones posibles del espacio de variables.

La formulación mide la diferencia exacta entre la predicción del modelo cuando la variable i está presente, expresada como $f(S \cup \{i\})$, y cuando está ausente, promediada sobre todos los subconjuntos posibles.

Esta base axiomática garantiza que los valores SHAP cumplan con tres propiedades fundamentales que aseguran la fiabilidad en auditorías financieras:

- Eficiencia local (Aditividad): La suma de las contribuciones SHAP de todas las variables, sumada al valor base del modelo (la media de las predicciones), iguala de forma exacta a la predicción final individual. No existe varianza residual sin explicar.

- Simetría: Si dos variables dependientes contribuyen de manera idéntica a todas las posibles coaliciones del modelo, reciben idéntico valor SHAP.
- Monotonía (Consistencia): Si la arquitectura del modelo se modifica de forma que el impacto marginal de una variable específica siempre aumenta o se mantiene estable, el valor SHAP atribuido a dicha variable nunca sufrirá una minoración.

La integración de esta formulación matricial en el simulador de viviendas de uso turístico transforma la herramienta predictiva en un sistema de diagnóstico estratégico. Permite al inversor identificar, con precisión matemática, qué palancas operativas y de gestión debe modificar para optimizar el comportamiento del activo en el mercado, garantizando así la interpretabilidad de la toma de decisiones.

3. METODOLOGÍA

El presente capítulo describe el proceso metodológico seguido para el diseño y desarrollo del simulador interactivo de decisiones de inversión en viviendas de uso turístico. La metodología adoptada es de carácter aplicado y combina la explotación de fuentes de datos públicas y gratuitas, el diseño de un modelo económico-financiero estructurado, la selección y entrenamiento de modelos de inteligencia artificial y el desarrollo de una interfaz interactiva orientada al soporte a la decisión.

El enfoque metodológico responde directamente a los objetivos específicos formulados en el Capítulo 1 y se articula en cinco fases secuenciales: obtención y preparación de los datos, definición de variables e indicadores, selección y justificación de los modelos de IA, diseño del motor financiero de escenarios y definición de la arquitectura general del sistema. Todo el desarrollo se ha realizado íntegramente con herramientas de código abierto y sin coste de infraestructura, con el fin de garantizar la replicabilidad del trabajo y su transferibilidad a otros contextos de análisis.

3.1. Fuentes de datos utilizadas y delimitación geográfica

El ámbito geográfico del presente trabajo queda delimitado a las ciudades de Madrid y Barcelona. Estas dos ciudades constituyen los mercados de viviendas de uso turístico de mayor dimensión y dinamismo en España, y presentan características diferenciadas en términos de oferta, precio medio por noche, tasa de ocupación y marco regulatorio local, lo que permite enriquecer el análisis comparativo y evaluar la robustez del simulador ante entornos con distintos niveles de competencia, densidad de oferta y restricción normativa.

La delimitación a dos ciudades responde también a criterios de viabilidad del proyecto en el plazo de ejecución disponible. El mayor volumen de datos y la mayor profundidad analítica obtenida con dos mercados bien caracterizados resulta preferible a una cobertura geográfica más amplia pero menos rigurosa.

Inside Airbnb constituye la fuente principal de datos para el entrenamiento y la validación de los modelos predictivos. Esta plataforma de acceso público publica

periódicamente conjuntos de datos detallados sobre los anuncios activos en las principales ciudades del mundo, incluyendo Madrid y Barcelona. Los archivos disponibles contienen información a nivel de anuncio individual sobre el tipo de propiedad, número de habitaciones y baños, capacidad máxima de huéspedes, localización por barrio y coordenadas geográficas, precio por noche, disponibilidad anual, número de reseñas y puntuación media. A partir de estas variables se derivan estimaciones de tasa de ocupación e ingreso mensual. Los datos son de carácter observacional y reflejan la oferta real activa en la plataforma en el momento de su extracción.

De forma complementaria, se utilizan las siguientes fuentes secundarias para enriquecer las variables del modelo y contextualizar el análisis:

Instituto Nacional de Estadística (INE). Proporciona datos de población, renta media por hogar y movimientos demográficos a escala municipal y de distrito, así como la Encuesta de Ocupación en Apartamentos Turísticos (EOAT), que aporta datos agregados sobre ocupación y precios medios en el sector del alquiler turístico a escala nacional y provincial.

Catastro. Ofrece información sobre superficie construida, año de construcción y referencia catastral de los inmuebles, variables relevantes para caracterizar la calidad y antigüedad del parque de viviendas disponible en cada ciudad.

OpenStreetMap. Permite incorporar variables de localización y entorno mediante la extracción de puntos de interés (POIs), accesibilidad al transporte público, proximidad a servicios y densidad de equipamientos por zona. Estas variables tienen una influencia documentada en el precio y la demanda de alojamiento turístico (Pérez-Sánchez et al., 2018).

Banco de España. Aporta series históricas de tipos de interés hipotecarios e índices de precio de la vivienda, necesarios para calibrar los parámetros del módulo de financiación del simulador y para contextualizar macroeconómicamente el análisis de rentabilidad.

Informe PwC-Strategy& sobre el impacto del alquiler de corta duración en España (2024). Proporciona referencias sobre la dinámica de los alojamientos de corta duración, su relación con los precios de la vivienda y su caracterización en los mercados de Madrid y Barcelona, incluyendo estimaciones sobre el volumen de oferta y el perfil del inversor.

Real Estate Market Outlook Spain 2025 (CBRE). Ofrece perspectivas actualizadas sobre la evolución del mercado inmobiliario español, las expectativas de rentabilidad en el segmento turístico y las tendencias de inversión previstas para el año en curso.

Informe Colliers 5 Claves Madrid vs Barcelona (2025). Aporta datos comparativos sobre ambos mercados en términos de oferta, demanda, rentabilidad y perspectivas de crecimiento, facilitando la calibración de los parámetros del motor de escenarios financieros.

Todas las fuentes utilizadas son de acceso público y su uso se realiza con fines exclusivamente académicos, respetando las condiciones de licencia establecidas por cada proveedor. Los datos procedentes de Inside Airbnb se obtienen en formato CSV. Las fuentes complementarias se utilizan en su modalidad de consulta y descarga de estadísticas agregadas, sin tratamiento automatizado adicional.

3.2. Proceso de obtención y limpieza de datos

Los datos procedentes de Inside Airbnb constituyen el insumo principal del proceso de preparación. El tratamiento de estos datos se estructura en las siguientes etapas, implementadas en Python mediante las librerías pandas y numpy.

Descarga y carga de datos. Se descargan los archivos de listings correspondientes a Madrid y Barcelona en su versión más reciente disponible en el momento de la realización del trabajo. Cada archivo contiene información de varios centenares de variables por anuncio, de las cuales se seleccionan únicamente aquellas relevantes para los objetivos del modelo.

Selección de variables. A partir del conjunto de variables disponibles, se realiza una selección basada en su relevancia teórica y en su disponibilidad efectiva en ambas ciudades. Las variables seleccionadas se agrupan en tres categorías: variables de caracterización del inmueble (tipo de propiedad, número de habitaciones, número de baños, capacidad máxima de huéspedes, localización por barrio y coordenadas geográficas), variables de mercado (precio por noche, disponibilidad anual, número de reseñas, puntuación media, tiempo como anfitrión) y variables derivadas (tasa de ocupación estimada, ingreso mensual estimado).

Tratamiento de valores ausentes. Se identifican y tratan los registros con valores ausentes en las variables seleccionadas. En función del porcentaje de ausencia y de la naturaleza de cada variable, se aplican estrategias de eliminación del registro cuando la ausencia supera un umbral definido, imputación por la mediana para variables numéricas continuas asimétricas, e imputación por la moda para variables categóricas.

Detección y tratamiento de valores atípicos. Se aplica un análisis de valores atípicos sobre las variables de precio por noche e ingreso estimado, que habitualmente presentan distribuciones con colas largas y valores extremos no representativos del mercado estándar. Los registros con valores extremos no justificables se eliminan o acotan mediante técnicas de winsorización en los percentiles 1 y 99.

Codificación de variables categóricas. Las variables categóricas, como el tipo de propiedad o el barrio de localización, se codifican mediante técnicas de codificación ordinal o one-hot encoding según el requerimiento de cada modelo. Para variables con alta cardinalidad, como el barrio, se aplica codificación por frecuencia o codificación objetivo supervisada con validación cruzada para evitar fugas de información.

Normalización y estandarización. Las variables numéricas continuas se normalizan o estandarizan según los requisitos de cada algoritmo. Los modelos basados en árboles de decisión (XGBoost y Random Forest) no requieren normalización, mientras que otros componentes del sistema que utilicen métricas de distancia sí la precisan.

División del conjunto de datos. El conjunto de datos preparado se divide en subconjuntos de entrenamiento y prueba aplicando una proporción de 80/20, con estratificación por ciudad para garantizar la representatividad de ambos mercados en cada subconjunto y evitar sesgos debidos al desbalance en el número de anuncios entre Madrid y Barcelona.

3.3. Definición de variables e indicadores económico-financieros

El modelo económico-financiero del simulador se construye a partir de un conjunto estructurado de variables organizadas en bloques funcionales. Su definición responde tanto a los fundamentos del análisis de inversiones inmobiliarias como a los indicadores habitualmente utilizados en la literatura sobre rentabilidad de viviendas de uso turístico (Jiao & Bai, 2020; Gibbs et al., 2018).

3.3.1. Inversión inicial y estructura de financiación

La inversión inicial comprende la totalidad de los desembolsos necesarios para adquirir y poner en explotación la vivienda de uso turístico. Se compone de los siguientes conceptos:

Precio de adquisición del inmueble: valor de compra del activo, expresado en euros, introducido directamente por el usuario como parámetro de entrada del simulador.

Gastos de compraventa: impuestos y costes asociados a la transmisión del inmueble, incluyendo el Impuesto sobre Transmisiones Patrimoniales (ITP) en el caso de vivienda de segunda mano o el Impuesto sobre el Valor Añadido (IVA) en obra nueva, más gastos notariales, registrales y de gestión. Se estiman habitualmente entre el 8% y el 12% del precio de adquisición en función de la comunidad autónoma.

Reforma y adecuación: costes de obras necesarias para adaptar el inmueble al uso turístico, variables en función del estado del inmueble en el momento de la compra.

Mobiliario y equipamiento: inversión en el equipamiento necesario para la explotación turística, incluyendo mobiliario, electrodomésticos, menaje y elementos decorativos.

Licencias y trámites: coste de obtención de la licencia o título habilitante de vivienda de uso turístico y de las demás gestiones administrativas asociadas.

Inversión total inicial (I_0): suma de todos los conceptos anteriores, que constituye la base de cálculo de los indicadores de rentabilidad.

La estructura de financiación contempla la distinción entre capital propio aportado por el inversor y capital ajeno obtenido mediante préstamo hipotecario. Los parámetros de financiación incluyen el porcentaje financiado sobre el precio de adquisición, el tipo de interés nominal aplicable, el plazo de amortización en años y la cuota mensual resultante, calculada mediante el sistema de amortización francés (cuota constante). El coste financiero total acumulado a lo largo del horizonte de análisis se incorpora como componente de los costes del modelo.

3.3.2. Ingresos, costes fijos y costes variables

Los ingresos brutos anuales (IBA) se calculan mediante la siguiente expresión:

$$\text{IBA} = \text{Precio medio por noche} \times \text{Tasa de ocupación} \times \text{Noches disponibles al año}$$

El precio medio por noche es estimado por el modelo Random Forest a partir de las características del inmueble y del mercado. La tasa de ocupación es estimada por el modelo XGBoost. Las noches disponibles al año se fijan en función de los parámetros operativos introducidos por el usuario. La proyección mensual de ingresos incorpora los ajustes de estacionalidad derivados del modelo Prophet, que diferencia entre temporada

alta, media y baja para cada ciudad. Se considera adicionalmente un factor de crecimiento interanual de los ingresos parametrizable por el usuario.

Los costes operativos se clasifican en dos categorías:

Costes fijos: aquellos que no varían en función del nivel de ocupación, entre los que se incluyen la cuota de la comunidad de propietarios, el seguro del hogar, el IBI y otros tributos municipales, los suministros en periodos de baja o nula ocupación, y la eventual cuota de una empresa de gestión externa.

Costes variables: aquellos que escalan con el nivel de ocupación o con el número de estancias, entre los que se incluyen los gastos de limpieza por rotación de huéspedes, el mantenimiento correctivo, las comisiones de las plataformas digitales de alquiler (habitualmente entre el 3% y el 15% de los ingresos brutos según la plataforma), y los costes de reposición de consumibles y pequeños equipos.

Adicionalmente, se incluyen los costes financieros derivados del servicio de la deuda hipotecaria y la carga fiscal correspondiente al rendimiento neto de la actividad, calculada conforme al régimen aplicable al rendimiento del capital inmobiliario en el Impuesto sobre la Renta de las Personas Físicas (IRPF), con la posibilidad de incorporar el régimen de actividad económica cuando el usuario así lo determine.

3.3.3. Flujo de caja neto

El flujo de caja neto anual (FCN) se obtiene como diferencia entre los ingresos brutos y la totalidad de los costes operativos, financieros y fiscales del ejercicio:

$$\text{FCN} = \text{IBA} - \text{Costes fijos} - \text{Costes variables} - \text{Costes financieros} - \text{Impuestos}$$

Este indicador constituye la variable central del modelo financiero y la base sobre la que se calculan los restantes indicadores de rentabilidad. El simulador proyecta el flujo de caja neto para un horizonte temporal de diez años, incorporando las hipótesis de crecimiento de ingresos y evolución de costes definidas para cada escenario de análisis.

La serie de flujos de caja proyectados alimenta directamente el cálculo del VAN, la TIR y el payback.

3.3.4. VAN, TIR y Payback

Los tres indicadores principales de rentabilidad de la inversión se definen del siguiente modo:

El Valor Actual Neto (VAN) se calcula como la suma de los flujos de caja netos anuales descontados a una tasa de descuento k , menos la inversión inicial I_0 :

$$VAN = -I_0 + \sum [FCN_t / (1 + k)^t] \text{ para } t = 1, 2, \dots, n$$

Un VAN positivo indica que la inversión genera valor por encima del coste de oportunidad del capital. La tasa de descuento k es parametrizable por el usuario y debe reflejar el coste del capital propio o la rentabilidad mínima exigida por el inversor.

La Tasa Interna de Retorno (TIR) es la tasa de descuento que hace que el VAN sea igual a cero. Representa la rentabilidad efectiva de la inversión en términos relativos y se compara con la tasa de descuento utilizada para determinar la conveniencia de la operación: si $TIR > k$, la inversión es financieramente viable.

El Payback o período de recuperación de la inversión indica el número de años necesarios para recuperar el desembolso inicial I_0 a través de los flujos de caja generados. El simulador calcula tanto el payback simple (sin descuento) como el payback descontado, que tiene en cuenta el valor temporal del dinero y resulta más conservador y financieramente riguroso.

Complementariamente, el modelo calcula los siguientes indicadores de síntesis:

Rentabilidad bruta: cociente entre los ingresos brutos anuales y el precio de adquisición del inmueble, expresado en porcentaje.

Rentabilidad neta: cociente entre el flujo de caja neto y la inversión total inicial, expresado en porcentaje.

Punto muerto de ocupación: tasa de ocupación mínima necesaria para que los ingresos brutos cubran la totalidad de los costes operativos, financieros y fiscales del ejercicio. Constituye un indicador de riesgo operativo de primer orden.

Rentabilidad sobre capital propio (ROE): cociente entre el flujo de caja neto y el capital propio aportado por el inversor, que refleja el efecto de apalancamiento financiero sobre la rentabilidad del inversor.

3.4. Selección y justificación de los modelos de IA

La selección de los modelos de inteligencia artificial utilizados en el simulador responde a criterios de adecuación al tipo de problema, rendimiento predictivo contrastado en la literatura académica y viabilidad de implementación con las herramientas disponibles. Los tres modelos seleccionados trabajan en secuencia para proporcionar las estimaciones que alimentan el motor financiero.

XGBoost para la predicción de ocupación. El algoritmo XGBoost (Extreme Gradient Boosting) es un método de aprendizaje automático supervisado basado en el ensamblado secuencial de árboles de decisión mediante boosting por gradiente. Ha demostrado un rendimiento superior en problemas de regresión y clasificación con variables tabulares de naturaleza heterogénea, características propias del conjunto de datos de Inside Airbnb. Su capacidad para gestionar valores ausentes de forma nativa, su robustez frente al sobreajuste mediante regularización L1 y L2, y su eficiencia computacional lo convierten en una opción idónea para la predicción de la tasa de ocupación a partir de las características del inmueble, el barrio, la época del año y las métricas de reputación del anuncio (Choy & Ho, 2023).

Random Forest para la estimación del precio óptimo por noche. El algoritmo Random Forest, basado en el ensamblado de árboles de decisión mediante bagging con

selección aleatoria de variables, ha sido ampliamente utilizado en la literatura para la predicción de precios en el mercado de alquiler de corta duración (Pérez-Sánchez et al., 2018; Choy & Ho, 2023). Su robustez frente al ruido en los datos, su capacidad para capturar relaciones no lineales entre las características del inmueble y el precio de mercado, y la facilidad de interpretación de la importancia de variables hacen de este algoritmo la elección más adecuada para el módulo de estimación del precio por noche. El modelo se entrena con validación cruzada temporal para preservar la dependencia cronológica de los datos (Magno et al., 2018).

Prophet para la proyección de estacionalidad. Prophet es un modelo de predicción de series temporales desarrollado por Meta, diseñado específicamente para series con patrones de estacionalidad múltiple marcada y efectos de calendario. Su arquitectura descompone la serie en tendencia, estacionalidad anual, estacionalidad semanal y efectos de días festivos, siendo especialmente adecuado para modelar la variabilidad estacional del mercado turístico. Su aplicación a la proyección mensual de la ocupación esperada y los ingresos estimados permite incorporar al motor financiero la heterogeneidad temporal de los flujos de caja, diferenciando entre temporada alta, media y baja para cada ciudad (Gibbs et al., 2018).

La interpretabilidad de los modelos XGBoost y Random Forest se aborda mediante el análisis de valores SHAP (SHapley Additive exPlanations), que cuantifican la contribución de cada variable predictora a la predicción individual de cada observación y a la importancia global del modelo. Este enfoque permite al usuario del simulador comprender qué características del inmueble o del mercado determinan en mayor medida las estimaciones de ocupación y precio, incrementando la transparencia y la confianza en los resultados (Lundberg & Lee, 2017).

3.5. Arquitectura del sistema

El simulador se concibe como un sistema modular compuesto por cuatro componentes principales que interactúan de forma secuencial, implementados

íntegramente en Python y desplegados localmente mediante Streamlit sin necesidad de infraestructura en la nube.

Módulo de datos. Responsable de la carga, limpieza y preprocesado de los datos de Inside Airbnb y de las fuentes complementarias. Genera los conjuntos de datos preparados que alimentan los modelos predictivos. Implementado con pandas y numpy, incluye todos los procedimientos descritos en el apartado 3.2.

Módulo de modelos predictivos. Contiene los tres modelos entrenados —XGBoost, Random Forest y Prophet— y expone sus predicciones como entradas parametrizadas para el motor financiero. Implementado con scikit-learn, xgboost y prophet. Incluye el análisis de interpretabilidad mediante la librería shap. Los modelos se serializan una vez entrenados y se cargan en tiempo de ejecución para garantizar tiempos de respuesta adecuados en la interfaz interactiva.

Motor financiero de escenarios. Recibe las predicciones de los modelos y los parámetros de inversión introducidos por el usuario, y calcula los indicadores económico-financieros descritos en el apartado 3.3 para tres escenarios simultáneos: optimista, neutro y pesimista. Los escenarios se definen aplicando variaciones porcentuales parametrizadas sobre las variables clave de ingresos y costes. Genera asimismo el análisis de sensibilidad de los indicadores de rentabilidad ante variaciones en las variables críticas del modelo.

Interfaz web interactiva. Desarrollada con Streamlit, permite al usuario introducir los parámetros de la inversión —precio del inmueble, características del activo, estructura de financiación, costes operativos y tasa de descuento—, seleccionar la ciudad y visualizar los resultados en forma de indicadores, gráficos interactivos generados con Plotly y tablas comparativas de escenarios. Incorpora adicionalmente un módulo de generación de informes automatizados mediante un modelo de lenguaje de gran escala (LLM) que interpreta los resultados del simulador en lenguaje natural y genera un resumen ejecutivo personalizado de la inversión analizada.

La comunicación entre módulos se realiza mediante estructuras de datos nativas de Python (dataframes de pandas y diccionarios), sin necesidad de arquitectura de microservicios ni dependencias externas de red, lo que simplifica el despliegue, garantiza

la reproducibilidad del entorno y facilita la portabilidad del sistema entre equipos de desarrollo.

4. DESARROLLO DEL SIMULADOR

El presente capítulo describe el proceso de desarrollo técnico del simulador interactivo de decisiones de inversión en viviendas de uso turístico. El sistema se ha construido de forma modular e iterativa, siguiendo la arquitectura definida en el capítulo anterior, e integrando tres modelos predictivos de inteligencia artificial, un motor de cálculo económico-financiero y una interfaz web interactiva de acceso público. Todo el desarrollo se ha realizado íntegramente en Python utilizando herramientas de código abierto y datos de acceso público, sin coste de infraestructura, con el fin de garantizar la reproducibilidad del trabajo y su transferibilidad a otros contextos de análisis.

4.1. Modelos predictivos

El núcleo analítico del simulador está compuesto por tres modelos de machine learning que trabajan en secuencia para estimar las variables críticas de demanda que alimentan el motor financiero: la tasa de ocupación esperada, el precio óptimo por noche y la proyección estacional de los ingresos. Los tres modelos han sido entrenados con datos reales procedentes de Inside Airbnb para las ciudades de Madrid y Barcelona, fuente consolidada como estándar observacional en la literatura académica sobre alquiler turístico de corta duración (Jiao & Bai, 2020).

Se utilizaron las extracciones de junio y septiembre de 2025 para ambas ciudades. La combinación de dos fechas distintas del mismo año se justifica metodológicamente con el objetivo de capturar la variabilidad de la oferta entre el inicio de la temporada alta estival y el cierre de la misma, consolidando un conjunto de entrenamiento más robusto y representativo que el que ofrecería una única extracción puntual. Tras el proceso de limpieza y preprocesado descrito en el Capítulo 3, el conjunto de datos definitivo comprende 69 142 anuncios activos distribuidos entre ambas ciudades.

4.1.1. Predicción de ocupación (XGBoost)

El primer modelo tiene como objetivo predecir la tasa de ocupación anual de un inmueble de uso turístico a partir de sus características observables en el momento de la inversión. Se seleccionó el algoritmo XGBoost (Extreme Gradient Boosting) por su robustez empírica contrastada para modelar relaciones no lineales en datos inmobiliarios tabulares de naturaleza heterogénea, su capacidad para gestionar valores ausentes de forma nativa y su mecanismo de regularización L1 y L2 que previene el sobreajuste (Choy & Ho, 2023).

Durante la fase de preparación de los datos se detectó un problema crítico de data leakage (fuga de información). Las variables correspondientes al volumen de reseñas mensuales y anuales concentraban el 76 % de la importancia predictiva del modelo en su primera versión. Este resultado no refleja capacidad predictiva genuina sino una contaminación metodológica: Inside Airbnb estima la ocupación de cada anuncio mediante el denominado Modelo de San Francisco, que multiplica el número de reseñas recibidas por un factor corrector. Incluir las reseñas como variables predictoras equivale a introducir indirectamente la variable objetivo en el modelo, invalidando su utilidad como herramienta de evaluación previa a la inversión. Una vez identificado y corregido este problema, el conjunto de features definitivo quedó compuesto exclusivamente por características del inmueble conocidas con anterioridad al inicio de la explotación comercial: ciudad, barrio, tipo de alojamiento, número de huéspedes, habitaciones, baños, camas, precio por noche, noches mínimas requeridas, disponibilidad anual, condición de superhost, número de anuncios del host, modalidad de reserva instantánea y puntuaciones de valoración. Esta decisión metodológica es coherente con el objetivo del simulador: predecir el comportamiento esperado del activo a partir de información disponible en el momento de la decisión de compra, no de resultados históricos de explotación.

El modelo fue entrenado con 42 462 registros y evaluado sobre 10 616, obteniendo los resultados que se recogen en la Tabla 1.

Métrica	Valor
MAE (Error Absoluto Medio)	0,1298 (12,98 puntos porcentuales)

RMSE (Raíz del Error Cuadrático Medio)	0,1662
R ² (Coeficiente de determinación)	0,597

Tabla 1. Métricas de evaluación del modelo XGBoost de predicción de ocupación.

El modelo explica el 59,7 % de la variabilidad de la tasa de ocupación a partir de las características observables del inmueble. El error medio de 13 puntos porcentuales es razonable dado que la ocupación depende también de factores no observables en el dataset, como la calidad fotográfica del anuncio, el algoritmo de posicionamiento de la plataforma o la estrategia de precios dinámica del propietario. Las variables con mayor importancia resultaron ser la condición de superhost (36,5 %), la puntuación de ubicación (10,9 %) y la valoración general del anuncio (6,9 %), resultados coherentes con la literatura sobre determinantes de la demanda en el mercado de alquiler turístico (Magno et al., 2018).

4.1.2. Predicción de precio óptimo por noche (Random Forest)

El segundo modelo tiene como objetivo estimar el precio óptimo por noche para un inmueble dado, entendido como el precio que el mercado soporta para activos con características similares en la misma zona geográfica. Se implementó el algoritmo Random Forest, basado en el ensamblado de árboles de decisión mediante bagging con selección aleatoria de variables en cada nodo. Su elección se justifica por su robustez frente a valores atípicos y su capacidad para capturar relaciones no lineales entre las características del inmueble y el precio de mercado, propiedades ampliamente documentadas en la literatura sobre valoración de activos turísticos (Pérez-Sánchez et al., 2018; Choy & Ho, 2023).

Previo al entrenamiento, se aplicó un filtro de exclusión para los inmuebles cuyo precio superaba el percentil 99 de la distribución, equivalente a 719 EUR por noche. Esta decisión se justifica para eliminar el segmento de alojamiento de lujo extremo o registros anómalos cuya presencia distorsionaría la estimación del precio de un VUT estándar de inversión residencial, que constituye el perfil objetivo del simulador. El conjunto de entrenamiento quedó compuesto por 42 037 registros y el de evaluación por 10 510. Los resultados se presentan en la Tabla 2.

Métrica	Valor
MAE	37,85 EUR
RMSE	59,54 EUR
R ²	0,696

Tabla 2. Métricas de evaluación del modelo Random Forest de predicción de precio por noche.

El modelo explica el 69,6 % de la variabilidad del precio por noche a partir de las características observables del inmueble. El error medio de 37,85 EUR sobre un precio mediano de mercado de 117 EUR representa un error relativo del 32 %, razonable dado que el precio depende también de factores no capturados por el modelo, como la estrategia de pricing dinámico del propietario o la calidad del contenido visual del anuncio. El análisis de importancia de variables confirmó que el tamaño del inmueble es el predictor dominante: el número de huéspedes (18,7 %), habitaciones (13,6 %) y camas (9,6 %) acumulan conjuntamente más del 42 % de la importancia total, en línea con los hallazgos de Pérez-Sánchez et al. (2018).

4.1.3. Proyección de estacionalidad (Prophet)

El tercer modelo aborda la dimensión temporal de los ingresos, incorporando al simulador la variabilidad estacional característica del mercado turístico. Se utilizó Prophet, un modelo de predicción de series temporales desarrollado por Meta Research, diseñado específicamente para series con patrones de estacionalidad múltiple y efectos de calendario (Taylor & Letham, 2018). Su elección frente a modelos clásicos como ARIMA se fundamenta en su capacidad nativa para modelar simultáneamente la estacionalidad anual y semanal, y para integrar de forma aditiva los efectos de días festivos nacionales, aspecto crítico para el sector turístico.

Los datos de entrenamiento se obtuvieron de los archivos de calendario de Inside Airbnb para Madrid y Barcelona, que registran la disponibilidad diaria de cada anuncio. A partir de 28 millones de registros de disponibilidad diaria, se construyeron series temporales de ocupación media diaria para cada ciudad, filtrando fechas desde enero de 2024. Las series resultantes comprenden 447 días para Madrid y 449 días para Barcelona. El modelo se configuró con estacionalidad anual y semanal en modo multiplicativo,

incorporando los festivos nacionales de España mediante la función nativa de Prophet. Evaluado sobre los últimos 60 días de cada serie, el modelo obtuvo un MAE de 11,4 puntos porcentuales para Madrid y de 12,1 puntos porcentuales para Barcelona. La proyección cubre un horizonte de 12 meses hacia adelante y es utilizada en el simulador para mostrar al usuario la evolución esperada de la ocupación a lo largo del año, diferenciando los periodos de temporada alta y baja mediante un gráfico interactivo con intervalo de confianza estadístico.

4.2. Motor de escenarios financieros

El motor de escenarios financieros es el componente central del simulador desde el punto de vista de la toma de decisiones de inversión. Su función es transformar las predicciones de los modelos de machine learning y los parámetros introducidos por el usuario en un conjunto estructurado de indicadores económico-financieros que permitan evaluar la viabilidad de la inversión bajo diferentes hipótesis de mercado.

Para dotar al sistema de capacidad de stress-testing, el motor calcula simultáneamente tres escenarios aplicando factores de ajuste sobre las variables de ingresos, costes y ocupación respecto al escenario base o neutro, tal y como se recoge en la Tabla 3.

Escenario	Factor ingresos	Factor costes	Factor ocupación
Optimista	+20 %	-10 %	+15 %
Neutro	Base	Base	Base
Pesimista	-20 %	+15 %	-20 %

Tabla 3. Factores de ajuste por escenario financiero.

Para cada escenario, el motor proyecta el flujo de caja neto anual durante el horizonte de análisis definido por el usuario, de entre cinco y veinte años, calculando los ingresos brutos como producto del precio por noche, la tasa de ocupación ajustada y el número de noches disponibles, con un factor de crecimiento interanual parametrizable. Los costes operativos se desglosan en costes fijos —comunidad de propietarios, seguro

del hogar, IBI, suministros y mantenimiento— y costes variables —limpieza por rotación de huéspedes, comisiones de la plataforma digital de alquiler y gestión externa—, a los que se añaden los costes financieros derivados del servicio de la deuda hipotecaria, calculada mediante el sistema de amortización francés de cuota constante, y la carga fiscal sobre el rendimiento neto en concepto de IRPF.

A partir de la serie de flujos de caja proyectados, el motor calcula los siguientes indicadores de rentabilidad para cada escenario: el Valor Actual Neto (VAN), definido como la suma de los flujos de caja descontados a la tasa establecida por el usuario menos la inversión inicial; la Tasa Interna de Retorno (TIR), cuyo cálculo se implementó mediante el método iterativo de Brent disponible en la librería SciPy, cuya convergencia matemática está garantizada frente al método de Newton-Raphson; el payback simple y el payback descontado, que cuantifican el número de años necesarios para recuperar el capital propio invertido en términos nominales y descontados respectivamente; la rentabilidad bruta, la rentabilidad neta, la rentabilidad sobre capital propio (ROE) y el punto muerto de ocupación, definido como la tasa mínima de ocupación necesaria para cubrir la totalidad de los costes operativos y financieros del ejercicio.

4.3. Interfaz web interactiva con Streamlit

La interfaz web del simulador ha sido desarrollada con Streamlit, un framework de Python que permite construir aplicaciones web interactivas sin necesidad de código adicional en HTML, CSS o JavaScript. Su elección frente a alternativas como Dash o Flask se justifica por la integración nativa con el ecosistema científico de Python, la eliminación de latencias entre la inferencia de los modelos y la visualización de resultados —aspecto crítico para simulaciones paramétricas en tiempo real— y la facilidad de despliegue en entornos de producción sin infraestructura de servidor propia.

La interfaz se estructura en las siguientes secciones, accesibles mediante desplazamiento vertical desde la página principal. El panel lateral izquierdo recoge los parámetros de caracterización del activo: ciudad, barrio, tipo de alojamiento, número de

huéspedes, habitaciones, baños, camas, noches mínimas, días disponibles al año, puntuaciones esperadas de valoración y perfil del anfitrión. Estos parámetros alimentan directamente los modelos predictivos y se actualizan en tiempo real ante cualquier modificación por parte del usuario.




Figura 1. Interfaz principal del simulador y panel lateral de parametrización del inmueble.

La sección de predicciones de los modelos de IA muestra los tres indicadores predictivos principales: ocupación estimada por XGBoost, precio óptimo por noche estimado por Random Forest e ingresos brutos anuales calculados como producto de ambas estimaciones. El usuario puede optar por utilizar las predicciones de los modelos o introducir manualmente sus propias hipótesis, lo que permite comparar el escenario de mercado con supuestos personalizados del inversor.



Figura 2. Módulo de estimaciones de los modelos XGBoost y Random Forest.

La proyección de estacionalidad presenta un gráfico interactivo elaborado con la librería Plotly que muestra la evolución esperada de la ocupación para los próximos doce meses según el modelo Prophet, incluyendo el intervalo de confianza estadístico para la ciudad seleccionada.




Figura 3. Gráfico de proyección de estacionalidad anual generado mediante Prophet.

La sección de parámetros de inversión, organizada en tres columnas, recoge la inversión inicial, la estructura de financiación y los costes operativos, así como los parámetros fiscales y el horizonte de análisis. Los resultados financieros presentan los indicadores clave del motor para los tres escenarios simultáneamente: inversión total, capital propio, VAN, TIR, rentabilidad neta y punto muerto de ocupación.

Resultados financieros					
Escenario Optimista					
Inversión total	Capital propio	VAN (EUR)	TIR	Rentabilidad neta	Punto muerto ocupación
251,800 EUR	119,800 EUR	2,943	5.2%	8.1%	29.5%
Escenario Neutro					
Inversión total	Capital propio	VAN (EUR)	TIR	Rentabilidad neta	Punto muerto ocupación
251,800 EUR	119,800 EUR	-103,210	-1.4%	4.5%	28.1%
Escenario Pesimista					
Inversión total	Capital propio	VAN (EUR)	TIR	Rentabilidad neta	Punto muerto ocupación
251,800 EUR	119,800 EUR	-206,326	-11.7%	1.0%	27.3%

Figura 4. Módulo financiero interactivo y parametrización de la inversión.

Los flujos de caja proyectados se visualizan mediante un gráfico de barras agrupadas que muestra el flujo de caja neto anual para cada escenario durante el horizonte de análisis, acompañado de una tabla detallada con el desglose anual del escenario neutro.



Figura 5. Gráfico de flujos de caja netos proyectados.

El análisis de sensibilidad representa la evolución del VAN ante variaciones en la tasa de ocupación entre el 10 % y el 75 %, permitiendo identificar visualmente el umbral de viabilidad financiera. La sección de interpretabilidad SHAP muestra la contribución individual de cada variable a la predicción de ocupación para el caso concreto analizado. El módulo de informe ejecutivo genera un informe de viabilidad estructurado y personalizado al pulsar un botón, con veredicto codificado en color, análisis de ocupación y precio, indicadores de rentabilidad, evaluación del punto muerto, estructura de financiación y tabla comparativa de escenarios.

El simulador ha sido desplegado en Streamlit Community Cloud, plataforma de despliegue gratuita integrada con GitHub, lo que permite el acceso público desde cualquier dispositivo con conexión a internet sin necesidad de instalación local. El código fuente completo del proyecto se encuentra disponible en el repositorio público <https://github.com/ivannavarros/tfm-simulador-vut>. El simulador puede ser consultado en la siguiente dirección web:

[SIMULADOR VUT - TFM IVÁN NAVARRO SUERO](https://github.com/ivannavarros/tfm-simulador-vut)

4.4. Interpretabilidad de los modelos (SHAP)

La interpretabilidad de los modelos de machine learning constituye un requisito fundamental en los sistemas de soporte a la decisión aplicados a contextos financieros. Un modelo que opera como caja negra carece de validez práctica en el análisis de inversiones, pues no proporciona al inversor información accionable sobre qué aspectos del activo o de su gestión pueden mejorar el resultado esperado. Para abordar esta dimensión se han implementado valores SHAP (SHapley Additive exPlanations), un método basado en la teoría de juegos cooperativos de Shapley que descompone la predicción de cada observación individual en contribuciones aditivas de cada variable predictora (Lundberg & Lee, 2017).

Los valores SHAP se calculan mediante la clase TreeExplainer de la librería shap, optimizada para modelos basados en árboles de decisión como XGBoost. Para cada inmueble analizado en el simulador, el sistema calcula en tiempo real los valores SHAP individuales correspondientes a las 17 variables del modelo de ocupación, identificando qué características contribuyen positivamente a la predicción —aumentando la ocupación estimada— y cuáles la penalizan, con su magnitud exacta expresada en las mismas unidades que la variable objetivo.

El análisis global de importancia SHAP, realizado sobre una muestra representativa de 1 000 anuncios, revela que las cinco variables con mayor impacto medio sobre la predicción de ocupación son, por orden de importancia: noches mínimas requeridas (0,0463), puntuación de ubicación (0,0442), condición de superhost (0,0373), valoración general (0,0362) y puntuación de calidad-precio (0,0356). Estos resultados son coherentes con la literatura sobre determinantes de la demanda en el mercado de alquiler turístico (Magno et al., 2018; Pérez-Sánchez et al., 2018) y proporcionan al inversor información accionable: reducir las noches mínimas requeridas, mejorar la calidad percibida de la ubicación o alcanzar la condición de superhost son las palancas de mayor impacto sobre la ocupación identificadas por el modelo. En el simulador, el análisis SHAP se presenta de forma individual para el caso concreto analizado, mostrando los diez factores con mayor contribución absoluta en un gráfico de barras horizontales con código de color.




Figura 6. Explicabilidad del modelo de ocupación mediante valores SHAP locales.

4.5. Módulo de reportes mediante IA Generativa

El módulo de generación de informes ejecutivos constituye el último componente del simulador y tiene como objetivo traducir los resultados numéricos del análisis financiero en un texto estructurado en lenguaje natural, accesible para usuarios con diferentes niveles de conocimiento técnico-financiero, reduciendo así la carga cognitiva asociada a la interpretación simultánea de múltiples métricas.

El módulo implementa un sistema de Generación de Lenguaje Natural (Natural Language Generation, NLG) basado en árboles de decisión y reglas lógicas deterministas. La decisión de prescindir de llamadas a Modelos de Lenguaje de Gran Escala externos mediante API responde a un requerimiento fundamental en el contexto del análisis financiero: el determinismo. Al estar basado en reglas condicionales rígidas, el módulo elimina el riesgo de alucinaciones estadísticas inherente a los modelos generativos, garantizando que el veredicto expresado en lenguaje natural sea invariablemente coherente con la matemática del flujo de caja descontado calculado por el motor financiero.

El sistema evalúa en primer lugar la viabilidad global de la inversión comparando el VAN del escenario neutro y del optimista con cero, emitiendo un veredicto codificado en tres niveles: inversión viable cuando el VAN neutro es positivo, inversión

condicionalmente viable cuando el VAN optimista es positivo pero el neutro es negativo, e inversión no viable en el horizonte analizado cuando el VAN es negativo en todos los escenarios. Este veredicto se presenta con código de color verde, amarillo o rojo respectivamente, proporcionando una señal visual inmediata que complementa el análisis cuantitativo. El informe se estructura en cinco secciones: análisis de ocupación y precio, indicadores de rentabilidad del escenario neutro, evaluación del punto muerto y margen de seguridad operativo, estructura de financiación y tabla comparativa de los tres escenarios. El estado del informe se gestiona mediante el mecanismo de sesión de Streamlit, de modo que persiste en pantalla al modificar cualquier parámetro del simulador, permitiendo al usuario comparar el análisis previo con los nuevos resultados.

5. RESULTADOS Y DISCUSIÓN

El presente capítulo recoge los resultados obtenidos a lo largo del proceso de desarrollo del simulador y los discute en relación con los objetivos planteados en el Capítulo 1. El análisis se organiza en tres bloques: la evaluación del rendimiento predictivo de los modelos de machine learning entrenados, la validación funcional del simulador mediante casos de uso representativos, y el análisis de sensibilidad de los indicadores financieros ante variaciones en las variables críticas del modelo.

5.1. Evaluación de los modelos de Machine Learning

La evaluación de los modelos predictivos constituye el primer nivel de validación del simulador. Un sistema de soporte a la decisión basado en inteligencia artificial solo puede considerarse metodológicamente válido si los modelos que lo sustentan han sido evaluados con rigor sobre datos no vistos durante el entrenamiento. En el presente trabajo, los tres modelos han sido entrenados y evaluados mediante una partición estricta 80/20, sin contaminación entre conjuntos, sobre un total de 69 142 anuncios reales procedentes de Inside Airbnb para Madrid y Barcelona.

5.1.1. Modelo XGBoost de predicción de ocupación

El modelo XGBoost, entrenado sobre 42 462 registros y evaluado sobre 10 616, obtuvo un coeficiente de determinación R^2 de 0,597, lo que significa que explica el 59,7 % de la variabilidad de la tasa de ocupación a partir de las características observables del inmueble. El Error Absoluto Medio (MAE) fue de 0,1298, equivalente a 13 puntos porcentuales, con un RMSE de 0,1662.

Estos resultados deben interpretarse en su contexto metodológico. Estudios similares que aplican algoritmos de machine learning a la predicción de ocupación en plataformas de alquiler turístico reportan valores de R^2 en el rango de 0,50 a 0,65 cuando se eliminan variables contaminantes derivadas del histórico de actividad (Choy & Ho, 2023). El valor obtenido se sitúa en la parte superior de este rango, lo que indica un rendimiento satisfactorio para el objetivo del simulador.

Una parte relevante de la varianza no explicada por el modelo se atribuye a factores estructuralmente no observables en el momento de la inversión: la calidad fotográfica del anuncio, el posicionamiento en el algoritmo de la plataforma, la estrategia de precios dinámica del propietario y la reputación acumulada a través de reseñas anteriores. Estos factores son por definición desconocidos en el momento de evaluar la viabilidad de una inversión futura, por lo que su exclusión del modelo es metodológicamente correcta, no una limitación evitable.

El análisis de importancia de variables mediante SHAP revela que los cinco factores con mayor impacto medio sobre la predicción de ocupación son las noches mínimas requeridas (0,0463), la puntuación de ubicación otorgada por los huéspedes (0,0442), la condición de superhost (0,0373), la valoración general del anuncio (0,0362) y la puntuación de calidad-precio (0,0356). La condición de superhost, que en el análisis de importancia tradicional del modelo aparecía como el predictor individual más relevante con un 36,5 % de importancia, confirma a través de SHAP que su contribución es consistentemente positiva sobre la ocupación estimada: los anuncios de superhosts reciben sistemáticamente más reservas, en coherencia con los estudios sobre el efecto de la reputación del anfitrión en el mercado de alquiler de corta duración (Magno et al., 2018).

5.1.2. Modelo Random Forest de predicción de precio

El modelo Random Forest, entrenado sobre 42 037 registros y evaluado sobre 10 510, alcanzó un R^2 de 0,696, explicando el 69,6 % de la variabilidad del precio por noche. El MAE fue de 37,85 EUR y el RMSE de 59,54 EUR, sobre un precio mediano de mercado de 117 EUR.

El error relativo del 32 % respecto al precio mediano es coherente con los valores reportados en la literatura para modelos de valoración hedónica aplicados al alquiler turístico. Pérez-Sánchez et al. (2018) obtienen errores relativos similares al predecir precios de Airbnb en ciudades españolas, atribuyendo la varianza no explicada a factores no estructurales como el estilo de decoración, la calidad de la gestión de las reseñas y las promociones temporales de precio. El presente modelo obtiene un rendimiento

competitivo respecto a estos antecedentes, lo que valida su uso como estimador del precio de referencia de mercado para un inmueble con características dadas.

El análisis de importancia de variables confirma que el tamaño del inmueble es el predictor dominante del precio: el número de huéspedes (18,7 %), habitaciones (13,6 %) y camas (9,6 %) acumulan conjuntamente el 42 % de la importancia total. Este resultado es coherente con la teoría de la valoración hedónica, según la cual el precio de un bien inmobiliario refleja la disposición a pagar del mercado por cada uno de sus atributos (Lancaster, 1966). La localización, capturada a través del barrio (5,9 %) y la ciudad (4,1 %), aparece como el segundo bloque de factores en importancia, en línea con el principio inmobiliario de que la localización constituye el determinante estructural del valor.

5.1.3. Modelo Prophet de proyección estacional

Los modelos Prophet entrenados para Madrid y Barcelona fueron evaluados sobre los últimos 60 días de cada serie temporal, obteniendo un MAE de 11,4 puntos porcentuales para Madrid y de 12,1 puntos porcentuales para Barcelona. Estos valores son comparables a los errores reportados en estudios de predicción de ocupación hotelera con modelos de series temporales en el contexto turístico español (Gibbs et al., 2018).

El análisis de la estacionalidad semanal revela un patrón consistente en ambas ciudades: los fines de semana presentan una ocupación sistemáticamente superior a los días laborables, con un efecto estacional positivo más pronunciado en Barcelona, cuya demanda turística tiene un perfil más marcadamente vacacional. La estacionalidad anual muestra picos en los meses de julio y agosto para ambas ciudades, con una caída en enero y febrero, y una recuperación progresiva en primavera. Estos patrones son coherentes con los datos publicados por el Instituto Nacional de Estadística en la Encuesta de Ocupación en Apartamentos Turísticos, lo que aporta validez externa a los resultados del modelo.

La inclusión de festivos nacionales mediante la función nativa de Prophet permite al modelo capturar el efecto de Semana Santa, puentes nacionales y períodos vacacionales, que generan picos de demanda puntuales difícilmente detectables con modelos de series temporales convencionales. Esta capacidad es especialmente relevante

para el simulador, ya que permite al usuario visualizar con mayor precisión los períodos de mayor rentabilidad esperada a lo largo del año.

5.2. Casos de uso del simulador interactivo

La validación funcional del simulador se lleva a cabo mediante el análisis de dos casos de uso representativos, uno para cada ciudad, que ilustran la capacidad del sistema para evaluar escenarios de inversión con diferentes perfiles de riesgo y rentabilidad. Los casos se construyen a partir de parámetros de mercado coherentes con los datos reales de Inside Airbnb y las referencias sectoriales disponibles.


5.2.1. Caso de uso A: inversión en Madrid, barrio de Universidad

El primer caso de uso analiza la viabilidad de una inversión en un apartamento completo de dos habitaciones y cuatro plazas en el barrio de Universidad (Madrid), zona céntrica de alta presión turística. Se plantea un precio de adquisición de 280 000 EUR, gastos de compraventa del 10 %, reforma de 8 000 EUR, mobiliario de 5 000 EUR y licencia de 800 EUR, lo que resulta en una inversión total inicial de 320 800 EUR. La operación se estructura sin financiación ajena (100 % de capital propio). El horizonte de análisis es de diez años y la tasa de descuento del 6 %.

Para este activo, el modelo XGBoost estima una tasa de ocupación del 17,2 %. Por su parte, el modelo Random Forest estima un precio óptimo por noche de 139 EUR. Con una disponibilidad de 300 noches al año, los ingresos brutos anuales estimados ascienden a 7 163 EUR.

El motor financiero arroja una rentabilidad neta del 0,5 % en el escenario neutro. El punto muerto de ocupación se sitúa en el 12,1 %. Al proyectar los flujos de caja, el VAN a diez años resulta fuertemente negativo, situándose en -306 051 EUR, con una TIR del -31,6 %.

Incluso en el escenario optimista simulado (+20 % en ingresos, +15 % en ocupación, -10 % en costes operativos), el VAN apenas asciende a -289 170 EUR con una TIR del -25,2 % y una rentabilidad neta del 1,2 %. El simulador emite un veredicto tajante de inversión no viable. Este resultado ilustra empíricamente una limitación real del mercado madrileño contemporáneo: los elevados precios de adquisición en los barrios céntricos, combinados con un horizonte de inversión corto (10 años), hacen imposible la viabilidad financiera del alquiler turístico puro sin aplicar estrategias agresivas de comercialización o apalancamiento que mejoren el retorno sobre el capital aportado.



Resultados financieros					
Escenario Optimista					
Inversion total	Capital propio	VAN (EUR)	TIR	Rentabilidad neta	Punto muerto ocupacion
321,800 EUR	321,800 EUR	-290,170	-25.3%	1.2%	11.9%
Escenario Neutro					
Inversion total	Capital propio	VAN (EUR)	TIR	Rentabilidad neta	Punto muerto ocupacion
321,800 EUR	321,800 EUR	-307,051	-31.6%	0.5%	12.1%
Escenario Pesimista					
Inversion total	Capital propio	VAN (EUR)	TIR	Rentabilidad neta	Punto muerto ocupacion
321,800 EUR	321,800 EUR	-325,145	N/A	-0.2%	12.9%

Figura 7. Informe ejecutivo y resultados financieros del Caso A (Madrid, Universidad).

5.2.2. Caso de uso B: inversión en Barcelona, barrio de la Dreta de l'Eixample


El segundo caso analiza un apartamento de características idénticas (dos habitaciones, cuatro plazas) en el barrio de la Dreta de l'Eixample (Barcelona). La inversión total asciende a 251 800 EUR. A diferencia del primer caso, la operación se apalanca financieramente mediante un préstamo hipotecario del 60 % del precio de adquisición (132 000 EUR) a un tipo de interés del 3,5 % a veinte años. El capital propio aportado por el inversor es de 119 800 EUR. El horizonte de análisis se establece en quince años y la tasa de descuento exigida en el 5 %.

Para este activo, equipado con la categoría de *superhost* y valoraciones excelentes, el modelo XGBoost estima una sólida tasa de ocupación del 50,0 %. Por su parte, el modelo Random Forest estima un precio óptimo de mercado de 226 EUR por noche. Con una disponibilidad de 300 noches, la herramienta proyecta unos ingresos brutos anuales de 33 992 EUR.

El motor financiero arroja resultados de gran interés analítico en el escenario neutro. Operativamente, el inmueble genera una rentabilidad neta positiva del 4,5 % y un ROE del 9,4 %. El punto muerto de ocupación se sitúa en el 28,1 %, proporcionando un holgado margen de seguridad de casi 22 puntos porcentuales respecto a la ocupación estimada, lo que otorga al proyecto una sólida resistencia ante caídas de demanda. La cuota hipotecaria mensual asciende a 766 EUR. Sin embargo, desde la perspectiva estrictamente financiera de los flujos de caja descontados, el VAN a quince años en el escenario neutro resulta de -103 210 EUR, con una TIR del -1,4 %.

A diferencia del caso anterior, el módulo de informes ejecutivos del simulador califica esta inversión como condicionalmente viable. Este veredicto se justifica al analizar la comparativa de escenarios: aunque el escenario pesimista hunde el VAN hasta los -206 326 EUR, bajo un escenario optimista (+20 % ingresos, +15 % ocupación, -10 % costes), la inversión logra revertir el déficit y alcanzar un VAN positivo de 2 943 EUR. Este caso ilustra a la perfección la capacidad del simulador como herramienta de soporte: demuestra al inversor que la adquisición de este activo exige unas condiciones de mercado y de gestión comercial sumamente favorables para generar valor sobre el 5 % exigido,

previniéndole de falsas expectativas basadas únicamente en la buena rentabilidad operativa mensual.



5.3. Análisis de sensibilidad de indicadores financieros

El análisis de sensibilidad constituye el tercer bloque de resultados y permite evaluar cómo varía el VAN del escenario neutro ante cambios en la tasa de ocupación, variable que concentra la mayor parte de la incertidumbre en el modelo financiero. El análisis se realiza manteniendo constantes todos los demás parámetros y variando la ocupación entre el 10 % y el 75 %.

Los resultados del análisis de sensibilidad para el Caso A (Madrid, barrio de Universidad) muestran la extrema rigidez de la inversión sin apalancamiento ante un precio de adquisición elevado. El gráfico revela que el VAN jamás alcanza el punto de inflexión ($\text{VAN} = 0$) dentro del abanico de ocupaciones simuladas. Incluso asumiendo una tasa de ocupación del 75 % —un valor estadísticamente excepcional en el sector de las viviendas de uso turístico no hoteleras—, el VAN permanece en un terreno fuertemente deficitario, anclado en torno a los -177 000 EUR. Esto confirma empíricamente que, bajo los parámetros actuales y el horizonte de diez años, la inversión es estructuralmente inviable independientemente de la tracción de la demanda.




Figura 9. Curva de sensibilidad del VAN para el Caso A.

Para el Caso B (Barcelona, la Dreta de l'Eixample), el umbral de viabilidad del VAN se sitúa en una ocupación próxima al 70 %, momento en el que el valor cruza a

territorio positivo situándose en 3 464,67 EUR. Este resultado indica que, para que la inversión genere valor por encima del 5 % exigido a quince años, el activo debe operar de forma sostenida con ocupaciones muy superiores a la estimación central del modelo XGBoost (50,0 %). El simulador cuantifica esta distancia al umbral de rentabilidad en 20 puntos porcentuales, demostrando al inversor que la operación comercial exige una gestión sumamente optimizada para resultar financieramente exitosa.




Figura 10. Curva de sensibilidad del VAN para el Caso B.

El análisis de sensibilidad también permite identificar visualmente que el VAN reacciona con gran brusquedad a las variaciones de ocupación cuando existe apalancamiento financiero, dado que los costes de la deuda elevan las exigencias de liquidez. En el Caso B (apalancado al 60 %), la pendiente de la curva de sensibilidad refleja el efecto amplificador del apalancamiento tanto sobre las ganancias potenciales en tramos altos de ocupación como sobre las pérdidas ante caídas de la demanda.

Estos resultados son coherentes con los principios del análisis de riesgo en inversiones inmobiliarias apalancadas, donde la deuda incrementa tanto la rentabilidad potencial en escenarios favorables como la exposición al riesgo de insolvencia en escenarios adversos. La visualización de esta dinámica en el simulador, mediante el gráfico de sensibilidad interactivo, permite al usuario comprender intuitivamente el perfil de riesgo de su inversión antes de tomar la decisión final.

6. CONCLUSIONES

El presente capítulo recoge las conclusiones principales del trabajo, contrastando los resultados obtenidos con los objetivos planteados en el Capítulo 1, identifica las limitaciones del estudio y propone las líneas de trabajo futuras que se derivan de los hallazgos y de las restricciones identificadas.

6.1. Conclusiones principales

El objetivo general del trabajo era diseñar y desarrollar un simulador interactivo de decisiones de inversión en viviendas de uso turístico que integrase modelos predictivos basados en inteligencia artificial, indicadores económico-financieros y análisis de escenarios. Este objetivo se ha alcanzado plenamente: el simulador se encuentra operativo, desplegado públicamente y accesible desde cualquier dispositivo, con todos sus componentes funcionales integrados en una única aplicación web. A continuación se sintetizan las conclusiones asociadas a cada objetivo específico.

En relación con la revisión del estado del arte, el análisis del mercado y de la literatura ha confirmado la existencia de la brecha que motivó el trabajo: aunque la investigación académica sobre predicción de precios y demanda en plataformas de alquiler turístico es abundante, son escasas las herramientas que trasladan estos avances a instrumentos prácticos de soporte a la decisión accesibles para el inversor no especializado. El simulador desarrollado contribuye a cerrar esta brecha integrando en una única herramienta capacidades que habitualmente se encuentran dispersas: predicción mediante machine learning, análisis financiero riguroso, interpretabilidad de modelos y generación automática de informes.

En relación con la identificación de variables y el modelo de cálculo financiero, el trabajo ha establecido un modelo económico-financiero completo y replicable que articula la inversión inicial, la estructura de financiación con amortización francesa, la estructura dual de costes fijos y variables característica del alquiler turístico, la fiscalidad y los indicadores de decisión —VAN, TIR, payback simple y descontado, rentabilidades

bruta, neta y sobre capital propio, y punto muerto de ocupación—. La implementación del cálculo de la TIR mediante el método de Brent garantiza la robustez numérica del motor en todo el rango de casos de uso.

En relación con el entrenamiento y evaluación de los modelos de inteligencia artificial, los tres modelos desarrollados alcanzan rendimientos satisfactorios y coherentes con la literatura. El modelo XGBoost de predicción de ocupación explica el 59,7 % de la variabilidad con un error medio de 13 puntos porcentuales, situándose en la parte superior del rango documentado en estudios comparables una vez eliminadas las variables contaminantes. El modelo Random Forest de predicción de precio explica el 69,6 % de la variabilidad con un error medio de 37,85 EUR. Los modelos Prophet capturan la estacionalidad anual y semanal de ambas ciudades con errores del 11,4 % y 12,1 %. Más allá de las métricas, la conclusión metodológica más relevante del proceso de modelización es la identificación y corrección del problema de fuga de información derivado del método de estimación de la ocupación de Inside Airbnb: las variables de reseñas, que concentraban el 76 % de la importancia predictiva inicial, constituían una contaminación de la variable objetivo. Su eliminación redujo el rendimiento aparente del modelo, pero garantizó su validez real como herramienta de evaluación previa a la inversión, lo que ilustra que en la modelización aplicada a decisiones financieras la validez metodológica debe prevalecer sobre la maximización de métricas.

En relación con el motor de escenarios y el análisis de sensibilidad, los resultados de los casos de uso demuestran la utilidad práctica del enfoque. El análisis comparado de los dos casos —Madrid y Barcelona— evidencia que el simulador discrimina correctamente entre perfiles de inversión con distinta viabilidad, cuantifica la distancia de cada operación a su umbral de rentabilidad y hace visible el efecto amplificador del apalancamiento financiero sobre la sensibilidad del VAN, que aumenta de aproximadamente 8 000 EUR a 11 000 EUR por punto porcentual de ocupación al introducir una financiación del 60 %. Los resultados confirman, asimismo, una conclusión de mercado relevante: a los precios actuales de adquisición en las zonas céntricas de Madrid y Barcelona, la viabilidad de la inversión en alquiler turístico exige niveles de ocupación significativamente superiores a la mediana del mercado, lo que

subraya el valor de una herramienta que permita identificar esta circunstancia antes de comprometer el capital.

En relación con la interfaz y la interpretabilidad, la integración de los valores SHAP en el simulador traduce las predicciones del modelo en información accionable para el inversor, identificando las palancas de gestión con mayor impacto sobre la ocupación esperada —noches mínimas requeridas, calidad de la ubicación y condición de superhost—. La decisión de implementar el módulo de informes mediante generación de lenguaje natural determinista, en lugar de modelos generativos externos, garantiza la coherencia matemática entre el informe y los cálculos del motor financiero, requisito que se considera irrenunciable en el contexto del análisis de inversiones.

Como conclusión general, el trabajo demuestra que es posible construir, con datos públicos y herramientas de código abierto, un sistema de soporte a la decisión metodológicamente riguroso, interpretable y accesible, que aproxima al inversor particular capacidades analíticas tradicionalmente reservadas al ámbito profesional. El simulador debe entenderse, en todo caso, como una herramienta académica de apoyo a la decisión, de carácter orientativo, cuyos resultados no constituyen asesoramiento de inversión.

6.2. Limitaciones del trabajo

El trabajo presenta limitaciones que deben explicitarse para delimitar el alcance de sus conclusiones y orientar su interpretación.

La primera limitación afecta a los datos de entrenamiento. La tasa de ocupación de Inside Airbnb es una estimación construida a partir del número de reseñas mediante el Modelo de San Francisco, no un dato observado de reservas reales. Los modelos entrenados heredan, por tanto, el error de esta estimación. Adicionalmente, como documenta Alsudais (2021), el conjunto de datos presenta imprecisiones conocidas en determinadas variables. La ausencia de datos oficiales de reservas —no publicados por

las plataformas— convierte esta limitación en estructural para toda la investigación basada en datos observacionales de alquiler turístico.

La segunda limitación es el alcance geográfico y temporal. Los modelos se han entrenado exclusivamente con datos de Madrid y Barcelona correspondientes a dos extracciones de 2025, por lo que sus predicciones no son extrapolables a otras ciudades ni a horizontes en los que la estructura del mercado haya cambiado significativamente. La vigencia de los modelos exige su reentrenamiento periódico con datos actualizados.

La tercera limitación se refiere al tratamiento del riesgo regulatorio. Como se ha expuesto en el marco teórico, el riesgo normativo es un factor de primer orden en este mercado —particularmente en Barcelona, con un horizonte anunciado de eliminación de licencias en 2028—. El simulador lo aproxima indirectamente mediante el escenario pesimista, pero no lo modeliza como variable probabilística explícita, ni incorpora la heterogeneidad regulatoria a nivel de barrio o zona urbanística.

La cuarta limitación afecta al módulo de proyección financiera. El modelo asume parámetros constantes durante el horizonte de análisis —tipo de interés, fiscalidad, crecimiento de ingresos—, no incorpora el valor residual del inmueble al final del horizonte ni la posible revalorización del activo, y no contempla estructuras de financiación distintas del préstamo hipotecario a tipo fijo con amortización francesa. Estas simplificaciones, razonables para una herramienta de evaluación preliminar, infraestiman el valor total de la inversión en escenarios de revalorización inmobiliaria.

Por último, la validación del simulador se ha realizado mediante casos de uso simulados y contraste con referencias de literatura y mercado, no mediante validación externa con datos reales de explotación de inversores. Una validación de este tipo requeriría acceso a contabilidades reales de viviendas turísticas, no disponible en el marco temporal y de recursos de este trabajo.

6.3. Líneas de trabajo futuras

De las conclusiones y limitaciones anteriores se derivan varias líneas de continuación del trabajo.

La primera línea es la ampliación del alcance geográfico del simulador a otras ciudades españolas con mercados de alquiler turístico relevantes —Valencia, Sevilla, Málaga, Palma—, aprovechando que Inside Airbnb publica datos para varias de ellas y que la arquitectura modular del sistema permite incorporar nuevas ciudades reentrenando los modelos sin modificar el motor financiero ni la interfaz.

La segunda línea es la modelización explícita del riesgo regulatorio, incorporando la zonificación urbanística municipal como variable del modelo —de especial relevancia en Barcelona, donde el PEUAT delimita zonas con regímenes diferenciados— y explorando la valoración de la inversión bajo incertidumbre normativa mediante técnicas de simulación de Montecarlo o árboles de decisión con probabilidades de cambio regulatorio.

La tercera línea es la adaptación del simulador a otras modalidades de explotación del activo residencial, en particular el alquiler por habitaciones orientado a estudiantes y trabajadores desplazados. Esta modalidad, en expansión en las grandes ciudades universitarias y de servicios, presenta una estructura económica diferenciada —contratos de media duración, menor rotación, costes operativos reducidos, ausencia de estacionalidad turística y un marco regulatorio menos restrictivo que el de las VUT— que la convierte en una alternativa de inversión directamente comparable sobre el mismo inmueble. La extensión del motor financiero a esta modalidad permitiría al inversor comparar, para un mismo activo, la rentabilidad y el riesgo del alquiler turístico, del alquiler por habitaciones y del alquiler residencial tradicional, transformando el simulador en una herramienta integral de optimización del uso del activo. Esta línea resulta especialmente pertinente en el contexto regulatorio actual, en el que el endurecimiento normativo sobre las VUT está reorientando parte de la inversión hacia modalidades de alquiler de media y larga estancia.

La cuarta línea es el enriquecimiento del modelo financiero con el valor residual del inmueble y su revalorización esperada, la simulación de financiación a tipo variable vinculada a proyecciones de tipos de interés, y la incorporación de la comparación sistemática con usos alternativos del activo descrita en la línea anterior.

La quinta línea es la evolución del módulo de informes hacia arquitecturas híbridas que combinen la fidelidad numérica de la generación determinista con la flexibilidad expresiva de los modelos de lenguaje de gran escala, mediante técnicas de generación aumentada por recuperación que restrinjan el contenido generado a los resultados calculados por el motor financiero.

Finalmente, la sexta línea es la validación externa del simulador con datos reales de explotación, en colaboración con gestores profesionales de viviendas turísticas, lo que permitiría calibrar los modelos con ocupaciones y precios observados y evaluar empíricamente la utilidad de la herramienta en procesos reales de decisión de inversión.

7. REFERENCIAS

Alsudais, A. (2021). Incorrect data in the widely used Inside Airbnb dataset. *Decision Support Systems*, 141, 113453. <https://doi.org/10.1016/j.dss.2020.113453>

Anthropic. (2026). *Claude* [Modelo de lenguaje grande]. <https://claude.ai>

Banco de España. (2025). *Estadísticas de tipos de interés e índices de precios de la vivienda*. <https://www.bde.es>

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>

CBRE España. (2025). *Real Estate Market Outlook Spain 2025*. CBRE Research.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>

Choy, L. H. T., & Ho, W. K. O. (2023). The use of machine learning in real estate research. *Land*, 12(4), 740. <https://doi.org/10.3390/land12040740>

Colliers. (2025). *5 Claves Madrid vs Barcelona: Mercado inmobiliario junio 2025*. Colliers Research.

García-López, M. À., Jofre-Monseny, J., Martínez-Mazza, R., & Segú, M. (2020). Do short-term rental platforms affect housing markets? Evidence from Airbnb in Barcelona. *Journal of Urban Economics*, 119, 103278. <https://doi.org/10.1016/j.jue.2020.103278>

Gibbs, C., Guttentag, D., Gretzel, U., Morton, J., & Goodwill, A. (2018). Pricing in the sharing economy: A hedonic pricing model applied to Airbnb listings. *Journal of Travel & Tourism Marketing*, 35(1), 46-56. <https://doi.org/10.1080/10548408.2017.1308292>

GitHub. (2026). *GitHub* [Plataforma de alojamiento de código]. <https://github.com>

Google. (2026). *Gemini* [Modelo de lenguaje grande]. <https://gemini.google.com>

- Google. (2026). *NotebookLM* [Asistente de investigación y software de ordenador]. <https://notebooklm.google.com>
- Inside Airbnb. (2025). *Get the data* [Conjunto de datos]. <http://insideairbnb.com/get-the-data/>
- Instituto Nacional de Estadística [INE]. (2025). *Encuesta de Ocupación en Apartamentos Turísticos (EOAT)*. <https://www.ine.es>
- Jiao, J., & Bai, S. (2020). An empirical analysis of Airbnb listings in forty American cities. *Cities*, 99, 102618. <https://doi.org/10.1016/j.cities.2020.102618>
- Lancaster, K. J. (1966). A new approach to consumer theory. *Journal of Political Economy*, 74(2), 132-157. <https://doi.org/10.1086/259131>
- Ley 12/2023, de 24 de mayo, por el derecho a la vivienda. *Boletín Oficial del Estado*, 124, de 25 de mayo de 2023. <https://www.boe.es/eli/es/l/2023/05/24/12/con>
- Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765-4774.
- Magno, F., Cassia, F., & Ugolini, M. M. (2018). Accommodation prices on Airbnb: Effects of host experience and market demand. *The TQM Journal*, 30(5), 608-620. <https://doi.org/10.1108/TQM-12-2017-0164>
- Microsoft. (2026). *Visual Studio Code* [Software de ordenador]. <https://code.visualstudio.com>
- Pérez-Sánchez, V. R., Serrano-Estrada, L., Martí, P., & Mora-García, R. T. (2018). The what, where, and why of Airbnb price determinants. *Sustainability*, 10(12), 4596. <https://doi.org/10.3390/su10124596>
- PwC-Strategy&. (2024). *Impacto del alquiler de corta duración en España*. PricewaterhouseCoopers Asesores de Negocios.

Python Core Team. (2024). *Python: A dynamic, open source programming language* [Software de ordenador]. Python Software Foundation. <https://www.python.org/>

Real Decreto 933/2021, de 26 de octubre, por el que se establecen las obligaciones de registro documental e información de las personas físicas o jurídicas que ejercen actividades de hospedaje y alquiler de vehículos a motor. *Boletín Oficial del Estado*, 257, de 27 de octubre de 2021. <https://www.boe.es/eli/es/rd/2021/10/26/933>

Shapley, L. S. (1953). A value for n-person games. En H. W. Kuhn & A. W. Tucker (Eds.), *Contributions to the Theory of Games II* (pp. 307-317). Princeton University Press.

Streamlit. (2024). *Streamlit* [Software de ordenador]. <https://streamlit.io/>

Taylor, S. J., & Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37-45. <https://doi.org/10.1080/00031305.2017.1380080>

Wang, F., Zou, Y., Zhang, H., & Shi, H. (2019). House price prediction approach based on deep learning and ARIMA model. *2019 IEEE 7th International Conference on Computer Science and Network Technology (ICCSNT)*, 303-307. <https://doi.org/10.1109/ICCSNT47585.2019.8962443>

Yrigoy, I. (2019). Rent gap reloaded: Airbnb and the shift from residential to touristic rental housing in the Palma Old Quarter in Mallorca, Spain. *Urban Studies*, 56(13), 2709-2726. <https://doi.org/10.1177/0042098018803261>

8. ANEXOS

Anexo A. Código fuente del simulador

El código fuente completo del proyecto se encuentra publicado en el repositorio público de GitHub <https://github.com/ivannavarros/tfm-simulador-vut>, y el simulador desplegado es accesible públicamente en <https://tfm-simulador-vut-3imkk2yy3exgfbenqpt4q.streamlit.app/>. La estructura del repositorio es la siguiente:

```
tfm-simulador-vut/
├── app/
│   └── simulador.py           # Aplicación web Streamlit
├── (interfaz)
├── src/
│   ├── models/               # Modelos entrenados serializados
│   │   ├── xgboost_ocupacion.pkl
│   │   ├── rf_precio.pkl.gz
│   │   ├── prophet_forecast_madrid.pkl
│   │   ├── prophet_forecast_barcelona.pkl
│   │   ├── shap_xgb.pkl
│   │   └── encoders_*.pkl
│   └── simulation/
│       └── motor_financiero.py # Motor de cálculo económico-financiero
├── notebooks/
│   ├── 01_exploracion_datos.ipynb
│   ├── 02_analisis_exploratorio.ipynb
│   ├── 03_modelo_ocupacion_xgboost.ipynb
│   ├── 04_modelo_precio_randomforest.ipynb
│   ├── 05_modelo_estacionalidad_prophet.ipynb
│   └── 06_shap_interpretabilidad.ipynb
├── data/processed/listings_clean.csv
├── reports/                   # Gráficos del análisis exploratorio
└── requirements.txt
```

Las principales dependencias del proyecto, recogidas en el archivo requirements.txt, son: pandas, numpy, scikit-learn, xgboost, prophet, shap, scipy, streamlit y plotly.

A continuación, se reproduce el código completo del motor de cálculo económico-financiero (src/simulation/motor_financiero.py), componente central del simulador, que implementa el modelo de cálculo descrito en el apartado 3.3 y el motor de escenarios descrito en el apartado 4.2:

python


```

# =====
# motor_financiero.py
# Motor de cálculo económico-financiero del simulador VUT
# =====

import numpy as np
from dataclasses import dataclass
from typing import Dict
from scipy.optimize import brentq

@dataclass
class ParametrosInversion:
    """Parámetros de entrada del inversor"""

    # Inversión inicial
    precio_compra: float
    gastos_compraventa_pct: float
    reforma: float
    mobiliario: float
    licencias: float

    # Financiación
    pct_financiado: float
    tipo_interes: float
    plazo_anos: int

    # Ingresos
    precio_noche: float
    ocupación: float
    noches_disponibles: int
    crecimiento_ingresos: float

    # Costes operativos
    coste_limpieza_rotacion: float
    rotaciones_año: int
    mantenimiento_anual: float
    comunidad_anual: float
    seguro_anual: float
    ibi_anual: float
    suministros_anual: float
    comision_plataforma_pct: float
    gestion_externa_pct: float

    # Fiscalidad
    tipo_irpf: float

    # Análisis
    tasa_descuento: float
    horizonte_anos: int

def calcular_cuota_hipoteca(capital: float, tipo_anual: float,
                           plazo_anos: int) -> float:
    """Sistema francés: cuota mensual constante"""
    if tipo_anual == 0 or capital == 0:
        return 0.0
    tipo_mensual = tipo_anual / 12
    n = plazo_anos * 12

```

```

cuota = capital * (tipo_mensual * (1 + tipo_mensual)**n) / \
        ((1 + tipo_mensual)**n - 1)
return cuota

def calcular_motor(params: ParametrosInversion,
                  escenario: str = 'neutro') -> Dict:
    """Calcula todos los indicadores financieros para un escenario."""

    factores = {
        'optimista': {'ingresos': 1.20, 'costes': 0.90, 'ocupacion':
1.15},
        'neutro':    {'ingresos': 1.00, 'costes': 1.00, 'ocupacion':
1.00},
        'pesimista': {'ingresos': 0.80, 'costes': 1.15, 'ocupacion':
0.80},
    }
    f = factores[escenario]

    # Inversión inicial
    gastos_compraventa = params.precio_compra *
params.gastos_compraventa_pct
    inversion_total = (params.precio_compra + gastos_compraventa +
params.reforma + params.mobiliario +
params.licencias)
    capital_ajeno = params.precio_compra * params.pct_financiado
    capital_propio = inversion_total - capital_ajeno

    # Financiación
    cuota_mensual = calcular_cuota_hipoteca(
        capital_ajeno, params.tipo_interes, params.plazo_anos)
    cuota_anual = cuota_mensual * 12

    # Proyección anual de flujos de caja
    flujos_caja = []
    for año in range(1, params.horizonte_anos + 1):

        ocupacion_ajustada = min(params.ocupacion * f['ocupacion'],
1.0)
        ingresos_brutos = (params.precio_noche * ocupacion_ajustada *
params.noches_disponibles * f['ingresos'] *
(1 + params.crecimiento_ingresos) ** (año -
1))

        coste_limpieza = (params.coste_limpieza_rotacion *
params.rotaciones_año * f['costes'])
        comision_plat = ingresos_brutos *
params.comision_plataforma_pct
        gestion_externa = ingresos_brutos * params.gestion_externa_pct

        costes_fijos = ((params.mantenimiento_anual +
params.comunidad_anual +
params.seguro_anual + params.ibi_anual +
params.suministros_anual) * f['costes'])

        costes_financieros = cuota_anual if año <= params.plazo_anos
else 0
        costes_operativos = (coste_limpieza + comision_plat +
gestion_externa + costes_fijos)

```

```

base_imponible = max(ingresos_brutos - costes_operativos -
                     costes_financieros, 0)
impuestos = base_imponible * params.tipo_irpf

fcf = (ingresos_brutos - costes_operativos -
       costes_financieros - impuestos)

flujos_caja.append({
    'año': año,
    'ingresos_brutos': round(ingresos_brutos, 2),
    'costes_operativos': round(costes_operativos, 2),
    'costes_financieros': round(costes_financieros, 2),
    'impuestos': round(impuestos, 2),
    'fcf': round(fcf, 2),
})

fcf_serie = np.array([x['fcf'] for x in flujos_caja])

# VAN
van = -inversion_total + sum(
    fcf / (1 + params.tasa_descuento)**t
    for t, fcf in enumerate(fcf_serie, 1))

# TIR (método de Brent)
def npv(tasa, flujos, inversion):
    return -inversion + sum(f / (1 + tasa)**t
                           for t, f in enumerate(flujos, 1))

tir = None
try:
    if npv(-0.99, fcf_serie, inversion_total) * \
        npv(10.0, fcf_serie, inversion_total) < 0:
        tir = brentq(npv, -0.99, 10.0,
                     args=(fcf_serie, inversion_total))
except Exception:
    tir = None

# Payback simple (sobre capital propio)
acumulado, payback = 0, None
for t, fcf in enumerate(fcf_serie, 1):
    acumulado += fcf
    if acumulado >= capital_propio:
        payback = t
        break

# Payback descontado (sobre capital propio)
acumulado_desc, payback_desc = 0, None
for t, fcf in enumerate(fcf_serie, 1):
    acumulado_desc += fcf / (1 + params.tasa_descuento)**t
    if acumulado_desc >= capital_propio:
        payback_desc = t
        break

# Rentabilidades
ingresos_año1 = flujos_caja[0]['ingresos_brutos']
rentabilidad_bruta = ingresos_año1 / params.precio_compra
rentabilidad_neta = flujos_caja[0]['fcf'] / inversion_total
roe = (flujos_caja[0]['fcf'] / capital_propio)

```

```

        if capital_propio > 0 else 0)

# Punto muerto de ocupación
costes_totales_año1 = (flujos_caja[0]['costes_operativos'] +
                      flujos_caja[0]['costes_financieros'])
punto_muerto_ocupacion = (
    costes_totales_año1 /
    (params.precio_noche * params.noches_disponibles)
    if params.precio_noche > 0 else None)

return {
    'escenario':          escenario,
    'inversion_total':    round(inversion_total, 2),
    'capital_propio':     round(capital_propio, 2),
    'capital_ajeno':      round(capital_ajeno, 2),
    'cuota_mensual':      round(cuota_mensual, 2),
    'van':                round(van, 2),
    'tir':                round(tir, 4) if tir is not None
else None,
    'payback':            payback,
    'payback_descontado': payback_desc,
    'rentabilidad_bruta': round(rentabilidad_bruta, 4),
    'rentabilidad_neta':  round(rentabilidad_neta, 4),
    'roe':                round(roe, 4),
    'punto_muerto_ocupacion': round(punto_muerto_ocupacion, 4)
    if punto_muerto_ocupacion else None,
    'flujos_caja':        flujos_caja,
}

def calcular_tres_escenarios(params: ParametrosInversion) -> Dict:
    """Calcula los tres escenarios simultáneamente"""
    return {
        'optimista': calcular_motor(params, 'optimista'),
        'neutro':    calcular_motor(params, 'neutro'),
        'pesimista': calcular_motor(params, 'pesimista'),
    }

```

La aplicación web (app/simulador.py) no se reproduce íntegramente en este anexo por su extensión, superior a las setecientas líneas de código. Implementa la interfaz descrita en el Capítulo 4: la carga de los modelos serializados con caché de recursos, las funciones de inferencia para XGBoost y Random Forest con codificación de las variables categóricas, las visualizaciones interactivas con Plotly, el cálculo de los valores SHAP en tiempo real mediante TreeExplainer y el módulo de informes ejecutivos con gestión de estado de sesión. Su código completo puede consultarse en el repositorio de GitHub indicado al inicio de este anexo.

Anexo B. Datos y licencias

Los datos utilizados en este trabajo proceden de Inside Airbnb (<http://insideairbnb.com>), proyecto independiente que publica sus conjuntos de datos bajo licencia Creative Commons CC BY 4.0, la cual permite su uso, distribución y transformación con la debida atribución de la fuente. Se utilizaron los archivos listings (características de los anuncios) y calendar (disponibilidad diaria) correspondientes a las extracciones de junio y septiembre de 2025 para las ciudades de Madrid y Barcelona. La *Tabla 4. Anexo B.* recoge el diccionario de las variables empleadas en los modelos predictivos.

Variable	Descripción	Tipo
ciudad	Ciudad del anuncio (Madrid/Barcelona)	Categórica
neighbourhood_cleansed	Barrio normalizado según nomenclatura oficial	Categórica
room_type	Tipo de alojamiento (vivienda completa, habitación privada, habitación compartida, habitación de hotel)	Categórica
accommodates	Capacidad máxima de huéspedes	Numérica
bedrooms	Número de habitaciones	Numérica
bathrooms	Número de baños	Numérica
beds	Número de camas	Numérica
price	Precio por noche (EUR)	Numérica
minimum_nights	Noches mínimas requeridas por reserva	Numérica
availability_365	Días disponibles en los próximos 365 días	Numérica
host_is_superhost	Condición de superhost del anfitrión	Binaria
host_listings_count	Número de anuncios gestionados por el anfitrión	Numérica
instant_bookable	Disponibilidad de reserva instantánea	Binaria
review_scores_rating	Valoración general del anuncio (1-5)	Numérica
review_scores_cleanliness	Valoración de limpieza (1-5)	Numérica
review_scores_location	Valoración de ubicación (1-5)	Numérica

review_scores_value	Valoración calidad-precio (1-5)	Numérica
ocupacion_estimada	Tasa de ocupación estimada (variable objetivo del modelo XGBoost)	Numérica

Tabla 4. Anexo B. Diccionario de variables empleadas en los modelos predictivos.

Cabe recordar, como se expone en los Capítulos 3 y 4, que la variable objetivo de ocupación es una estimación construida por Inside Airbnb a partir del número de reseñas mediante el denominado Modelo de San Francisco, y que las variables relativas al volumen de reseñas fueron excluidas del conjunto de predictores para evitar la fuga de información documentada en el apartado 4.1.1. El software empleado en el desarrollo — Python y las librerías citadas en el Anexo A, así como el framework Streamlit— es íntegramente de código abierto, lo que garantiza la reproducibilidad completa del trabajo sin coste de licencias.

Anexo C. Declaración de uso de inteligencia artificial generativa

En cumplimiento de la normativa aplicable a los Trabajos Fin de Máster y en coherencia con la declaración responsable firmada al inicio de este documento, se detalla a continuación el uso de herramientas de inteligencia artificial generativa en la elaboración del presente trabajo.

Durante el desarrollo del TFM se han utilizado los asistentes de inteligencia artificial Claude (Anthropic) y Gemini (Google), así como NotebookLM (Google) como herramienta de organización y consulta de las fuentes documentales del proyecto. Estas herramientas se han empleado como apoyo en las siguientes tareas: asistencia en la redacción, revisión de estilo y estructuración de los capítulos de la memoria; generación, depuración y documentación de código Python durante el desarrollo del simulador, los modelos predictivos y el motor financiero; y apoyo en la búsqueda, verificación y formateo de las referencias bibliográficas conforme al estilo APA de 7ª edición.

Todo el contenido elaborado con apoyo de estas herramientas ha sido revisado, verificado, editado y validado por el autor, quien asume la plena responsabilidad sobre el

contenido final del trabajo. Las decisiones metodológicas, la selección y evaluación de los modelos, el diseño de la arquitectura del simulador, el análisis e interpretación de los resultados y las conclusiones son de elaboración propia. Los datos, métricas y resultados presentados en la memoria proceden de la ejecución real del código y de los modelos desarrollados, y no de generación automática por parte de las herramientas de IA.

Resulta pertinente señalar que el uso de estas herramientas guarda coherencia conceptual con el propio objeto del trabajo: del mismo modo que el simulador desarrollado emplea la inteligencia artificial como instrumento de apoyo a la decisión humana —sin sustituirla—, las herramientas de IA generativa han actuado en este trabajo como instrumento de apoyo a la elaboración académica, permaneciendo el criterio, la verificación y la responsabilidad final en el autor.